

Inteligência Artificial Aplicada à Predição de Reincidência em Violência Doméstica

Análise Preditiva de Dados da Ficha RVD-R Portuguesa

João Pedro Azevedo Rodrigues | 2022177

Licenciatura em Engenharia Informática

Projeto

Orientador: Prof. Vitor Santos

Porto, junho de 2026

Declaração de Originalidade

Eu, João Pedro Azevedo Rodrigues, número de estudante 2022177, aluno(a) do curso de Licenciatura em Engenharia Informática do ISTECH Porto, declaro, sob compromisso de honra, que o presente relatório de projeto, intitulado “Inteligência Artificial Aplicada à Predição de Reincidência em Violência Doméstica” é um trabalho original e da minha autoria.

Confirmando que este trabalho foi elaborado especificamente para a disciplina de Projeto e que todas as fontes de informação utilizadas, incluindo ideias, dados e textos de outros autores, foram devidamente citadas e referenciadas de acordo com as normas académicas aplicáveis.

Assumo total responsabilidade pela integridade e veracidade dos conteúdos apresentados neste relatório, garantindo que não foi plagiado ou copiado, parcial ou totalmente, de qualquer outra fonte sem a devida atribuição.

Mais declaro que este trabalho não foi anteriormente submetido ou apresentado, no todo ou em parte, para avaliação em qualquer outra disciplina ou instituição.

Com esta declaração, reafirmo o meu compromisso com os princípios da ética e da integridade académica.

Agradecimentos

A realização deste Projeto é o culminar de três anos de trabalho, dedicação, dores de cabeça e muitas aprendizagens, sempre acompanhado pela família, amigos, colegas e professores, que me apoiaram, consolaram, deram força e motivação, tornando todo este caminho mais especial.

Agradeço aos professores que marcaram o meu percurso, fundamentais a aguçar a minha curiosidade e a preparar-me, para além da teoria, compreender também o mundo e a sociedade.

Ao Professor Vítor Santos, por quem tive o enorme prazer de ser orientado e que sempre se demonstrou empenhado e disposto a ajudar e a ensinar e a quem agradeço especialmente o apoio no desenvolvimento de todos os elementos desta apresentação.

Ao Professor Doutor Hélder Pinto, um enorme obrigado não só pela oportunidade de realizar este Projeto de Investigação, mas também por todos os momentos de partilha e cumplicidade ao longo deste percurso.

E, em especial, ao Professor João Rebelo, parte fundamental no despertar do meu interesse pela área da Informática e a figura mais importante durante estes três anos de ensino; a sua dedicação, humildade e inteligência serão carinhosamente sempre recordadas por mim.

Agradeço também aos meus colegas do Projeto Science4Policy, Daniel Silva e Leonardo Brito, pelo companheirismo e proatividade sempre demonstrados em todo o processo, e em especial ao Professor Marcelo Nogueira, cujos conhecimentos técnicos e ensinamentos.

Maria, agradeço-te por todo o apoio incondicional, amor, paciência, carinho e confiança; sem ti nunca me teria inscrito nesta aventura, muito menos teria a capacidade de a levar a bom porto. A tua resiliência é para mim uma inspiração e foi nela que me alavanquei muitas vezes durante este desafio.

Aos meus Avós, por quem tudo fiz para que se orgulhem do neto. Ao meu irmão, para quem procuro sempre ser um exemplo melhor. E a toda a minha restante família, estendendo este agradecimento também aos pais da minha namorada, que sempre me apoiaram e acreditaram em mim e nas minhas capacidades, o meu mais sincero obrigado do fundo do coração.

Agradeço também aos meus amigos que me acompanham desde sempre e que me incentivaram e apoiaram nesta caminhada. Sem vocês nada teria sido igual.

Uma menção também para os meus colegas da Faculdade, que tornaram todo este percurso mais fácil. Com muita boa-disposição e entreaajuda, foram uma peça fundamental desta etapa e jamais me irei esquecer de todos os momentos por que passámos.

Por último, mas a mais importante, quero agradecer à minha Mãe. Estejas onde estiveres, tenho a certeza de que hoje estarás com um sorriso no rosto e eu com uma lágrima no olho

Resumo

A violência doméstica é um problema social persistente em Portugal, com cerca de 30 000 ocorrências anuais e taxas de reincidência que rondam os 22,7% nos agressores acompanhados. A avaliação de risco de primeira linha apoia-se na ficha RVD-R, cuja capacidade preditiva, usada isoladamente, é apenas moderada. Este trabalho investiga se modelos de Machine Learning podem apoiar a previsão de reincidência a partir das respostas a esse instrumento.

Perante o bloqueio de acesso a dados reais, gerou-se um conjunto de dados sintéticos calibrado por estatísticas oficiais portuguesas, com 22 500 agressores e uma taxa de reincidência de 29,6%. Sobre estes dados, construiu-se um pipeline reproduzível de pré-processamento — com codificação tripla das respostas e divisão por agressor para evitar fuga de informação — e treinaram-se e compararam-se três modelos: árvore de decisão, Random Forest e XGBoost, afinados por otimização Bayesiana. A interpretabilidade foi assegurada por valores SHAP, e a solução foi exposta numa camada de serviço com validação clínica.

O Random Forest foi o modelo retido para a camada operacional, com um AUC-ROC de 0,710 e uma sensibilidade de 0,607, claramente superior à do XGBoost na deteção de reincidentes — fator decisivo num domínio em que o custo dos falsos negativos é elevado. Os resultados confirmam um sinal preditivo modesto mas explorável e mostram que a interpretabilidade pode ser preservada sem perda relevante de desempenho. As principais limitações decorrem da natureza sintética dos dados, ficando a validação sobre dados reais como trabalho futuro.

Palavras-chave: violência doméstica, reincidência, Machine Learning, avaliação de risco, RVD-R, interpretabilidade.

Abstract

Domestic violence is a persistent social problem in Portugal, with around 30,000 reported occurrences per year and recidivism rates of about 22.7% among monitored offenders. First-line risk assessment relies on the RVD-R form, whose predictive power, used on its own, is only moderate. This work investigates whether Machine Learning models can support recidivism prediction from the answers to that instrument.

Given the lack of access to real data, a synthetic dataset was generated, calibrated against official Portuguese statistics, comprising 22,500 offenders with a 29.6% recidivism rate. A reproducible preprocessing pipeline was built — with triple encoding of the answers and an offender-level train/test split to prevent information leakage — and three models were trained and compared: decision tree, Random Forest and XGBoost, tuned by Bayesian optimisation. Interpretability was ensured through SHAP values, and the solution was exposed through a service layer with clinical validation.

Random Forest was the model retained for the operational layer, with a ROC-AUC of 0.710 and a sensitivity of 0.607, clearly higher than XGBoost's at detecting recidivists — a decisive factor in a domain where the cost of false negatives is high. The results confirm a modest but exploitable predictive signal and show that interpretability can be preserved without relevant loss of performance. The main limitations stem from the synthetic nature of the data, leaving validation on real data as future work.

Keywords: domestic violence, recidivism, Machine Learning, risk assessment, RVD-R, interpretability.

Índice

<i>Inteligência Artificial Aplicada à Predição de Reincidência em Violência Doméstica</i>	<i>i</i>
<i>Declaração de Originalidade</i>	<i>i</i>
<i>Agradecimentos</i>	<i>ii</i>
<i>Resumo</i>	<i>iii</i>
<i>Abstract</i>	<i>iv</i>
<i>Índice</i>	<i>v</i>
<i>Índice de Figuras</i>	<i>ix</i>
<i>Índice de Tabelas</i>	<i>xi</i>
<i>Lista de Acrónimos e Siglas</i>	<i>xiii</i>
1. Introdução	1
1.1. Enquadramento e Contextualização do Problema	1
1.2. Motivação	1
1.3. Objetivos.....	2
1.4. Planeamento do Projeto	3
1.5. Estrutura do Relatório	4
2. Revisão de Literatura e Estado da Arte	5
2.1. Violência Doméstica em Portugal.....	5
2.2. Instrumentos de Avaliação de Risco	5
2.3. Reincidência em Violência Doméstica.....	6
2.4. Aprendizagem Automática Aplicada a Risco Criminal.....	7
2.5. Geração de Dados Sintéticos em Domínios Sensíveis.....	8
2.6. Síntese e Posicionamento do Presente Trabalho	9
3. Análise e Desenho da Solução	10
3.1. Visão Geral da Solução.....	10
3.2. Análise de Requisitos	10
3.2.1. Requisitos Funcionais	11

3.2.2.	Requisitos Não-Funcionais	16
3.3.	Arquitetura do Sistema.....	20
3.3.1.	Camadas funcionais.....	20
3.3.2.	Drivers arquiteturais	21
3.4.	Tecnologias e Bibliotecas Seleccionadas	22
3.5.	Conjunto de Dados Sintéticos.....	22
3.5.1.	Caracterização da ficha RVD-R.....	22
3.5.2.	Fontes para calibração	23
3.5.3.	Geração assistida por LLM	23
3.5.4.	Validação dos dados sintéticos	24
3.6.	Desenho do Pipeline de Pré-processamento	24
3.6.1.	Ingestão batch	24
3.6.2.	Limpeza e validação	25
3.6.3.	Codificação e feature engineering	25
3.6.4.	Tratamento do desequilíbrio entre classes	25
3.7.	Desenho da Solução de Modelação.....	26
3.7.1.	Modelos candidatos e afinação de hiperparâmetros.....	26
3.7.2.	Estratégia de validação	27
3.7.3.	Métricas de avaliação	27
3.7.4.	Interpretabilidade dos modelos.....	28
3.7.5.	Níveis de risco operacionais.....	29
4.	Desenvolvimento do Projeto	30
4.1.	Processo de Desenvolvimento	30
4.2.	Implementação da Geração de Dados Sintéticos	30
4.2.1.	Estrutura do gerador	30
4.2.2.	Diálogo com o LLM e iteração dos parâmetros	31
4.2.3.	Calibração com estatísticas oficiais	31
4.2.4.	Validação pós-geração.....	31
4.3.	Implementação do Pipeline de Pré-processamento	32
4.3.1.	Carregamento e construção da variável-alvo.....	32
4.3.2.	Codificação das respostas.....	32
4.3.3.	Variáveis agregadas e matriz final	33
4.4.	Implementação dos Modelos.....	33
4.4.1.	Divisão treino-teste por agressor	33
4.4.2.	Afinação de hiperparâmetros com Optuna.....	34
4.4.3.	Treino final, avaliação e interpretabilidade	35
4.4.4.	Função operacional de previsão com explicação.....	36
4.5.	Desafios Técnicos	38
4.6.	Alternativas Consideradas	39

5. Testes e Validação	40
5.1. Estratégia de Testes	40
5.2. Testes de Software	40
5.2.1. Testes unitários	40
5.2.2. Testes de integração	40
5.2.3. Testes de sistema	40
5.3. Casos de Teste.....	41
5.4. Avaliação Experimental dos Modelos	42
5.5. Tratamento de Fuga de Informação entre Episódios.....	42
5.6. Resultados dos Testes.....	43
5.7. Validação dos Requisitos	44
6. Resultados e Discussão.....	45
6.1. Apresentação de Resultados	45
6.2. Discussão Crítica.....	55
6.3. Análise de Preditores e Interpretabilidade (XAI)	58
6.4. Limitações dos Resultados.....	67
7. Conclusão e Trabalho Futuro	68
7.1. Sumário e Contributos	68
7.2. Objetivos Alcançados	68
7.3. Limitações	69
7.4. Trabalho Futuro	69
7.5. Considerações sobre Inteligência Artificial.....	70
7.6. Apreciação Final	72
Referências	74
Anexos	79
Anexo A: Cronograma.....	79
Anexo B: Glossário Técnico-Clínico das variáveis RVD-R.....	79
Secção A: Fatores comuns (foco no agressor)	79
7.6.1. Secção B: Severidade do incidente.....	80
7.6.2. Secção C1: Vulnerabilidade nas relações de intimidade	80
7.6.3. Secção C2: Vulnerabilidade contra crianças e jovens	80
7.6.4. Secção C3: Vulnerabilidade contra pessoas idosas	81
7.6.5. Variáveis agregadas (engenharia de variáveis)	81

7.7.	Anexo C: Código-fonte e dados	81
-------------	--	-----------

Índice de Figuras

Figura 1: Arquitetura do sistema em quatro camadas: o fluxo de uma avaliação RVD-R desde a ingestão dos dados, pelo pré-processamento e pela modelação, até à entrega da previsão explicada ao profissional na camada de serviço.....	20
Figura 2: Trajetória da otimização Bayesiana com Optuna para os três classificadores: AUC obtido em validação cruzada (GroupKFold, k=5) ao longo das tentativas, em painéis paralelos.....	35
Figura 3: Distribuição da variável-alvo no conjunto de modelação (primeira avaliação por agressor): número e proporção de agressores reincidentes e não reincidentes.	46
Figura 4: Distribuição dos agressores pelos cinco níveis de risco técnico atribuídos pela ficha RVD-R, no conjunto de modelação.	47
Figura 5: Taxa observada de reincidência por nível de risco RVD-R; a linha tracejada indica a média global.....	48
Figura 6: Matrizes de confusão para os três classificadores no conjunto de teste, em contagens absolutas.	49
Figura 7: Curvas ROC para os três classificadores no conjunto de teste, com AUC respetivo.....	50
Figura 8: Curvas precisão-sensibilidade para os três classificadores no conjunto de teste, com AUC-PR respetivo.	51
Figura 9: Distribuição do AUC obtido em validação cruzada (GroupKFold, k=5) por modelo, em diagrama de caixa.	52
Figura 10: Análise de threshold para o Random Forest (modelo retido para a camada operacional): precisão, sensibilidade e F1 em função do limiar de decisão.....	54
Figura 11: AUC por tipologia de violência (C1, C2, C3 e OUTRA) para cada um dos três classificadores.	55
Figura 12: Comparação entre o baseline RVD-R (regra ELEVADO/EXTREMO → reincide) e os três modelos de Machine Learning.....	56
Figura 13: Demonstração quantitativa do efeito de fuga de informação: AUC do Random Forest treinado apenas sobre primeiras avaliações (correto) face ao treino sobre todas as avaliações (com fuga).	58
Figura 14: Heatmap das vinte variáveis mais correlacionadas com a reincidência, no conjunto de treino.....	60
Figura 15: Top 15 variáveis por importância intrínseca (impurity-based Gini) calculadas pelo Random Forest no conjunto de treino.....	61
Figura 16: Análise dos falsos negativos do modelo selecionado, agregados por nível de risco técnico.....	62

Figura 17: Importância SHAP média absoluta por variável, calculada sobre o Random Forest no conjunto de teste (top 15).	63
Figura 18: Distribuição dos valores SHAP por amostra e por variável (top 15) para o Random Forest. A cor representa o valor da variável; o eixo horizontal a contribuição para a previsão da classe Reincide.	64
Figura 19: Explicação SHAP de uma previsão classificada como de risco residual (probabilidade inferior a 33%), com decomposição a partir do valor base do modelo.....	65
Figura 20: Explicação SHAP de uma previsão classificada como de risco moderado (probabilidade entre 33% e 66%).	65
Figura 21: Explicação SHAP de uma previsão classificada como de risco grave (probabilidade superior a 66%).	66
Figura 22: Gráficos de dependência SHAP para as quatro variáveis de maior impacto médio sobre o Random Forest, com coloração pela variável de interação detetada automaticamente em cada painel.....	67

Índice de Tabelas

Tabela 1 - RF Integração de Avaliações RVD-R	11
Tabela 2 - RF Construção da Variável-Alvo sem fuga de informação	12
Tabela 3 - RF Pipeline de pré-processamento reprodutível.....	12
Tabela 4 – RF Divisão treino/teste por agressor	13
Tabela 5 - RF Treino comparativo de modelos	13
Tabela 6 - RF Afinação automática de hiperparâmetros.....	14
Tabela 7 - RF Avaliação com métricas adequadas e análise por subgrupo.....	14
Tabela 8 - RF Explicação das previsões (XAI global e local).....	15
Tabela 9 - RF Serviço de inferência com validação clínica	15
Tabela 10 - RNF Reprodutibilidade.....	16
Tabela 11 - RNF Interpretabilidade operacional	17
Tabela 12 - RNF Conformidade regulamentar (Regulamento de IA e RGPD)	17
Tabela 13 - RNF Equidade entre subgrupos	18
Tabela 14 - RNF Portabilidade e custo zero.....	18
Tabela 15 - RNF Segurança da camada de serviço	19
Tabela 16: Hiperparâmetros ótimos do XGBoost identificados pela otimização Bayesiana com Optuna após cinquenta tentativas.....	34
Tabela 17: Estrutura do pedido JSON enviado pela interface (front end) ao endpoint POST /prever: campos, tipos, obrigatoriedade e descrição.	37
Tabela 18: Estrutura da resposta JSON devolvida pelo endpoint POST /prever: previsão, nível de risco, recomendação e explicação SHAP.	38
Tabela 19: Casos de teste representativos por nível (unitário, integração e sistema), com o input fornecido e o output esperado.	41
Tabela 20: Resultado da execução dos testes de software por nível: número de testes e estado (todos passam).....	43
Tabela 21: Caracterização do conjunto de dados sintéticos utilizado: total de avaliações, agressores e vítimas únicos, período coberto, agressores reincidentes e tipologias representadas.	45
Tabela 22: Divisão do conjunto em treino e teste por agressor, com a proporção de reincidentes em cada subconjunto.....	45
Tabela 23: Taxa observada de reincidência por nível de risco RVD-R no conjunto de modelação.	47
Tabela 24: Métricas dos três classificadores no conjunto de teste: accuracy, precisão, sensibilidade, F1 e AUC.	48

Tabela 25: Relatório de classificação detalhado por classe e por modelo no conjunto de teste.	49
Tabela 26: Métricas obtidas por validação cruzada (GroupKFold, k=5) no conjunto de treino, reportadas como média $\pm$ desvio padrão.	52
Tabela 27: Métricas em função do limiar de decisão para o modelo retido, com destaque para os limiares operacionais 0,33 e 0,66.	52
Tabela 28: AUC por tipologia de violência (C1, C2, C3 e OUTRA) para cada um dos três classificadores.	54
Tabela 29: Comparação entre o baseline RVD-R (regra ELEVADO/EXTREMO $\rightarrow$ reincide) e os três modelos de Machine Learning.	56
Tabela 30: Comparação de AUC do Random Forest entre o regime correto (primeira avaliação por agressor) e o regime com fuga de informação (todas as avaliações).	56
Tabela 31: Vinte variáveis com correlação de Pearson mais elevada com a variável-alvo no conjunto de treino, em valor absoluto.	59
Tabela 32: Falsos negativos do modelo retido agregados por nível de risco técnico RVD-R, no conjunto de teste.	61

Lista de Acrónimos e Siglas

APAV	Associação Portuguesa de Apoio à Vítima
AUC	Area Under the Curve
AUC-PR	Area Under the Precision-Recall Curve
AUC-ROC	Area Under the Receiver Operating Characteristic Curve
CIG	Comissão para a Cidadania e a Igualdade de Género
CITECA	Centro de Investigação em Tecnologias e Comunicação Aplicadas (ISTEC-Porto)
CSV	Comma-Separated Values
DASH	Domestic Abuse, Stalking and Honour-Based Violence (instrumento internacional)
F1	F1-score (média harmónica de precisão e sensibilidade)
FAIR	Findable, Accessible, Interoperable, Reusable (princípios de gestão de dados científicos)
IA	Inteligência Artificial
ISTEC	Instituto Superior de Tecnologias Avançadas
LLM	Large Language Model (modelo de linguagem de grande dimensão)
ML	Machine Learning (aprendizagem automática)
N/A	Não Aplicável (categoria de resposta na ficha RVD)
NUIPC	Número Único de Identificação de Processo Crime
ODARA	Ontario Domestic Assault Risk Assessment (instrumento internacional)
PAVD	Programa para Agressores de Violência Doméstica
PR	Precision-Recall
RASI	Relatório Anual de Segurança Interna
ROC	Receiver Operating Characteristic
RVD	Ficha de Avaliação de Risco em Violência Doméstica
RVD-1L	Ficha RVD de 1.ª Linha (em vigor entre 2014 e 2025; histórica)
RVD-R	Ficha RVD Revista (em vigor desde julho de 2025; instrumento atual)
S/I	Sem Informação (categoria de resposta na ficha RVD)

SARA	Spousal Assault Risk Assessment (instrumento internacional)
SHAP	SHapley Additive exPlanations (técnica de Explainable AI)
SIGO	Sistema Integrado de Gestão Operacional (das forças de segurança)
SMOTE	Synthetic Minority Over-sampling Technique
TPE	Tree-structured Parzen Estimator (algoritmo do Optuna)
XAI	Explainable Artificial Intelligence (IA explicável)
XGBoost	eXtreme Gradient Boosting

1. Introdução

Este capítulo introduz o problema da violência doméstica em Portugal, apresenta a motivação deste projeto, os objetivos gerais e específicos, o âmbito delimitado e descreve, por fim, a estrutura do restante relatório.

1.1. Enquadramento e Contextualização do Problema

A violência doméstica é, em Portugal, o crime mais praticado em contexto familiar e um dos que mais marca o quotidiano das vítimas. Segundo o Relatório Anual de Segurança Interna (IASI) de 2025, foram registadas 29 778 ocorrências de violência doméstica, com 25 homicídios associados [1]. No mesmo ano, a Associação Portuguesa de Apoio à Vítima (APAV) apoiou 16 630 pessoas: 76% dos crimes reportados ocorreram em contexto de violência doméstica [2]. Apesar da estabilidade dos números anuais, muitas situações nunca chegam às autoridades, e cerca de 62,5% dos inquéritos abertos são arquivados ainda em fase de investigação [3].

Para apoiar a avaliação de risco em contexto policial, Portugal adotou, em 2014, a Ficha de Avaliação de Risco em Violência Doméstica de 1.ª Linha (RVD-1L), aplicada pelos órgãos de polícia criminal no primeiro contacto com a vítima. Em julho de 2025, este instrumento foi substituído pela Ficha de Avaliação de Risco em Violência Doméstica Revista (RVD-R), aprovada pela Portaria n.º 228/2025/1 [6], que integra avanços empíricos recentes e passa a adaptar-se às diferentes tipologias do crime: relações de intimidade, violência filio-parental e violência contra idosos [7]. A RVD-R organiza-se em secções dedicadas ao agressor, à vulnerabilidade da vítima, ao histórico de violência e ao impacto em menores, e mantém a classificação tripartida do risco (baixo, médio ou elevado) que orienta as medidas de proteção posteriores. A reincidência, entendida como a repetição de atos violentos pelo mesmo agressor, mantém-se um dos principais desafios do sistema, com taxas reportadas de 22,7% no Programa para Agressores de Violência Doméstica (PAVD) e 53,4% de vítimas em situação de violência repetida segundo a APAV [2], [4].

1.2. Motivação

A identificação precoce de situações com maior probabilidade de reincidência pode contribuir para uma alocação mais eficiente de recursos de proteção e de medidas de acompanhamento, em linha com as prioridades definidas pela Estratégia Nacional para a Igualdade e a Não Discriminação 2018-2030 [23] e pela estratégia nacional portuguesa para a inteligência artificial [48]. Os instrumentos atuais de avaliação de risco, quando aplicados isoladamente, têm capacidade preditiva limitada [5]. As técnicas de Machine Learning (ML) — também designadas em português por aprendizagem automática — oferecem uma via promissora [36]: permitem

integrar dezenas de indicadores em simultâneo, captar interações não-lineares entre fatores de risco e gerar estimativas probabilísticas que complementam o juízo profissional do agente no terreno.

A motivação pessoal para este projeto vem do interesse em aplicar as competências de ciência de dados e de engenharia informática que tenho vindo a desenvolver ao longo da licenciatura a um problema social com impacto direto em vidas humanas. A ausência de estudos publicados em Portugal que apliquem ML à predição de reincidência em violência doméstica com base em dados da ficha RVD-R é uma lacuna que este trabalho procura começar a explorar.

1.3. Objetivos

O presente trabalho integra-se no projeto Inteligência Artificial para a Previsão de Reincidência na Violência Doméstica em Portugal (IA_PRVD_PT), conduzido pelo CITECA do ISTECS-Porto no âmbito da candidatura Science4Policy 2025 [22]. O seu objetivo geral é desenvolver e validar modelos de inteligência artificial para a previsão de reincidência em violência doméstica em Portugal, a partir dos dados estruturados da ficha RVD-R. Este trabalho contribui para esse objetivo através da componente de modelação preditiva e do respetivo pipeline de pré-processamento. O desenho do sistema operacional e da interface de apoio à decisão é desenvolvido em paralelo por outro membro da equipa, sem dependência direta com o presente relatório.

Os objetivos específicos do presente trabalho são:

- Explorar e caracterizar os dados sintéticos da ficha RVD-R, identificando as variáveis mais relevantes para a previsão da reincidência e avaliando a qualidade, completude e consistência do conjunto gerado.
- Construir um pipeline reproduzível de ingestão em lotes (batch) e de pré-processamento que assegure o tratamento de valores ausentes, a codificação de variáveis categóricas e o tratamento do desequilíbrio entre classes.
- Implementar, treinar e comparar pelo menos três famílias de modelos supervisionados de classificação (árvore de decisão como linha de base interpretável, Random Forest e XGBoost, este último da família do gradient boosting), em linha com o plano metodológico da candidatura S4P-25.
- Avaliar comparativamente os modelos com métricas adequadas a contextos de classes desequilibradas (precisão, sensibilidade, F1, AUC-ROC e AUC-PR), com particular atenção à sensibilidade e à redução de falsos negativos.
- Analisar a importância relativa dos preditores e a interpretabilidade dos modelos com recurso a técnicas de Explainable AI (XAI), que assume o papel de apoio, e não substituição, do juízo profissional.

- Identificar limitações éticas e metodológicas da abordagem, em particular as decorrentes do uso de dados sintéticos e dos riscos de viés algorítmico em contextos de alta sensibilidade social.

O projeto centra-se apenas na ficha RVD-R, enquanto instrumento de primeira linha aplicado pelos órgãos de polícia criminal no primeiro contacto com a vítima, e no contexto português. O trabalho não implementa nem compara empiricamente instrumentos internacionais como o ODARA, o SARA ou o DASH, embora estes sejam abordados no estado da arte para enquadramento conceptual.

Em virtude das restrições legais associadas ao acesso a dados reais, os modelos são treinados e avaliados sobre um conjunto de dados sintéticos, gerado a partir de estatísticas oficiais portuguesas e da literatura empírica disponível. Assim, a transferibilidade dos resultados para dados reais fica assumida como trabalho futuro e encontra-se fora do âmbito desta entrega.

O presente relatório cobre a componente de modelação preditiva, o pipeline de pré-processamento, a avaliação experimental dos modelos e a explicação das previsões através de técnicas de interpretabilidade. Para demonstrar a viabilidade de integração da solução, foi ainda desenvolvido um protótipo técnico mínimo de serviço de inferência, responsável por receber uma avaliação RVD-R estruturada e devolver uma previsão explicada. Contudo, este protótipo não corresponde a um sistema operacional completo, nem inclui o desenvolvimento de uma interface final de apoio à decisão ou de um dashboard, componentes que ficam reservadas para fases posteriores da iniciativa CITECA/ISTEC-Porto.

1.4. Planeamento do Projeto

O desenvolvimento do projeto desenrolou-se em cinco fases sequenciais, com sobreposição parcial entre fases adjacentes:

- Fase 1: Revisão de literatura e caracterização do domínio (violência doméstica em Portugal, instrumento RVD-R e fatores de risco associados à reincidência).
- Fase 2: Geração e validação do conjunto de dados sintéticos calibrado a partir das estatísticas oficiais portuguesas.
- Fase 3: Análise exploratória dos dados e estudo de correlações entre indicadores e reincidência.
- Fase 4: Conceção do pipeline de pré-processamento, implementação e validação dos modelos de Machine Learning.
- Fase 5: Redação do relatório, revisão e preparação da defesa.

O cronograma detalhado, com as datas previstas para cada fase, é apresentado no Anexo A.

1.5. Estrutura do Relatório

Para além desta introdução, este relatório contém mais seis capítulos. O segundo capítulo revê o estado da arte, com o enquadramento da violência doméstica em Portugal, os instrumentos de avaliação de risco atualmente em uso e as aplicações de Machine Learning na predição de reincidência. O terceiro capítulo apresenta a análise e o desenho da solução, com o domínio do problema, os requisitos funcionais e não funcionais e a arquitetura de modelação proposta. O quarto capítulo descreve o desenvolvimento do projeto, do gerador de dados sintéticos ao pipeline de pré-processamento e aos próprios modelos. O quinto capítulo cobre os testes e a validação, com particular atenção ao tratamento da fuga de informação entre episódios. O sexto capítulo apresenta os resultados e a discussão crítica das métricas obtidas, da importância das variáveis e das limitações observadas. O sétimo e último capítulo conclui o trabalho com a síntese dos contributos, considerações sobre inteligência artificial e uma apreciação final.

2. Revisão de Literatura e Estado da Arte

2.1. Violência Doméstica em Portugal

Esta secção retoma o enquadramento da introdução com mais detalhe. Os dados oficiais portugueses dos últimos anos mostram um número anual de ocorrências estabilizado em torno das trinta mil: em 2023 foram registadas 30 279 ocorrências [24] e em 2025, 29 778 [1]. A APAV apoiou, em 2024, 16 630 pessoas e registou 31 242 crimes, dos quais 76% em contexto de violência doméstica [2]. A base epidemiológica de referência para a investigação nacional foi estabelecida pelo Inquérito Nacional sobre a Violência Exercida contra Mulheres e Homens [28], cujos resultados ainda são hoje invocados em estudos posteriores.

O perfil agregado dos casos é claro. Segundo a APAV (2024), 80,6% das vítimas eram do sexo feminino e 70,5% dos agressores do sexo masculino; cônjuges, companheiros ou ex-companheiros representavam mais de 45% dos agressores identificados. Em 53,4% das situações, as vítimas estavam expostas a episódios repetidos de violência ao longo do tempo [2]. O impacto desta exposição prolongada na saúde mental está documentado em estudos recentes que reportam taxas elevadas de depressão e perturbação de stress pós-traumático em mulheres portuguesas com histórico de trauma interpessoal [26], [27].

A resposta judicial mostra limitações estruturais. Em 2024, 62,5% dos inquéritos por violência doméstica foram arquivados ainda em fase de investigação (23 509 de um total de 37 614) e apenas 13,9% resultaram em acusação [3]. A esta assimetria entre denúncia e acusação junta-se a estimativa de que uma proporção significativa dos casos nunca chega a ser reportada. O conjunto reforça a necessidade de instrumentos que, no primeiro contacto, ajudem a identificar os casos de maior risco.

A expressão mais letal do fenómeno é o homicídio em contexto de violência doméstica. Em 2025 registaram-se 25 homicídios deste tipo, 21 dos quais com vítimas mulheres [1]. A série histórica do Observatório de Mulheres Assassinadas regista 709 mulheres assassinadas entre 2002 e 2025; em grande parte destes casos, terceiros tinham conhecimento prévio de violência [25]. Embora os homicídios representem uma fração reduzida do volume total de ocorrências, são a categoria que mais justifica o investimento em modelos de avaliação de risco — uma ferramenta de deteção precoce com potencial impacto direto em vidas humanas.

2.2. Instrumentos de Avaliação de Risco

A avaliação de risco é uma componente central da resposta policial à violência doméstica. Permite traduzir a informação recolhida no momento da denúncia numa classificação reproduzível do risco e, a partir desta, ativar medidas de proteção proporcionais [29]. Os instrumentos validados

reduzem a variabilidade da decisão humana e ajudam a priorizar os casos que mais precisam de intervenção.

Em Portugal, esta avaliação foi durante mais de uma década feita com a Ficha de Avaliação de Risco em Violência Doméstica (RVD). A RVD divide-se em ficha de 1.ª linha, aplicada pelos órgãos de polícia criminal no primeiro contacto com a vítima, e ficha de 2.ª linha, de seguimento. Em vigor desde 1 de novembro de 2014, manteve-se sem alterações até 2025. A Portaria n.º 228/2025/1 de 21 de maio aprovou a Ficha de Avaliação de Risco em Violência Doméstica Revista (RVD-R), em vigor desde 1 de julho de 2025 [6]. A RVD-R resulta de uma revisão científica conduzida pela Egas Moniz School of Health & Science, coordenada por Iris Almeida, e introduz três alterações principais [7]: questões específicas para crianças, jovens e idosos, ausentes na versão anterior; incorporação dos avanços empíricos mais recentes em fatores preditivos de reincidência; e distinção explícita entre preditores estáticos (como o historial criminal) e variáveis dinâmicas que evoluem no tempo (consumo de substâncias, situação laboral). A primeira destas alterações responde a uma lacuna identificada na literatura internacional sobre avaliação de risco em faixas etárias mais jovens [33].

A nível internacional, três instrumentos servem objetivos análogos aos da RVD. O Ontario Domestic Assault Risk Assessment (ODARA) [32] e o Spousal Assault Risk Assessment (SARA) [31] são os mais utilizados em jurisdições anglo-saxónicas. O Domestic Abuse, Stalking and Honour-Based Violence (DASH) integra-se na mesma família. Hanson, Helmus e Bourgon publicaram uma meta-análise sobre a validade preditiva destes instrumentos: confirma capacidade discriminativa moderada e estabelece o ponto de partida a partir do qual abordagens baseadas em Machine Learning têm sido exploradas [5].

2.3. Reincidência em Violência Doméstica

Não existe na literatura uma definição única de reincidência em violência doméstica. O termo abrange duas realidades empiricamente distintas: a reincidência criminal — quando um agressor regressa ao sistema judicial ou prisional — e a repetição de episódios de violência sobre a mesma vítima, independentemente de haver registo criminal. No projeto IA_PRVD_PT (Inteligência Artificial para a Previsão de Reincidência na Violência Doméstica em Portugal), em que este trabalho se insere, a reincidência é definida como a repetição de atos violentos pelo mesmo agressor, identificada através do histórico policial (SIGO), do histórico judicial e de fichas RVD anteriores.

As estimativas portuguesas para cada uma destas dimensões diferem substancialmente. O Programa para Agressores de Violência Doméstica (PAVD), em funcionamento desde 2014, registou uma taxa de reincidência criminal de 22,7% num universo de 9 061 participantes [4]. Este valor capta apenas os agressores que voltaram ao sistema e subestima o fenómeno real: muitos

casos nunca chegam às autoridades e 62,5% dos inquéritos abertos são arquivados [3]. Em paralelo, os dados da APAV mostram que 53,4% das vítimas apoiadas estavam expostas a episódios repetidos de violência [2]. Esta diferença sugere que a probabilidade real de repetição é significativamente superior à reincidência criminal observada.

A literatura portuguesa identifica um conjunto consistente de fatores associados à evolução grave dos casos. O estudo da Faculdade de Direito da Universidade do Porto sobre homicídio conjugal documentou a presença de violência prévia em cerca de metade dos casos analisados, acompanhada por dependência alcoólica, instabilidade psicológica e não-aceitação do fim da relação — este último fator presente em aproximadamente 40% dos crimes [8]. Morais-Gonçalves, Lopes-Borges e Gaspar propõem uma grelha de monitorização com 44 itens preditivos da reincidência: destacam-se o desemprego, as atitudes favoráveis à violência, os problemas psicológicos, o historial de violência prévia e o consumo de substâncias [9]. Pires de Sousa e colaboradores quantificaram estatisticamente alguns destes fatores em 283 casos do tribunal do Porto (2010-2013): o desemprego apresenta uma razão de probabilidades de 3,18 como preditor de não-aceitação do programa de reintegração social [35]. As ameaças de morte e as tentativas de femicídio são indicadores particularmente robustos de letalidade próxima [30].

A nível internacional, a revisão sistemática de McDonagh e colaboradores (1945-2024) identifica 25 estudos longitudinais sobre preditores psicológicos de reincidência em violência entre parceiros íntimos. A revisão organiza-os em cinco categorias: traços de personalidade, raiva e hostilidade, crenças e motivação, défices neurocognitivos e trauma [34]. O relatório do Ministério Público sobre homicídios em contexto de violência doméstica em 2023, baseado em 22 casos, confirma a ordem de relevância destes fatores no contexto português [21].

2.4. Aprendizagem Automática Aplicada a Risco Criminal

Os instrumentos atuais de avaliação de risco têm capacidade preditiva limitada e os fatores que concorrem para a evolução grave dos casos são múltiplos. Estas duas razões justificam a investigação de abordagens complementares baseadas em Machine Learning. Os algoritmos supervisionados permitem integrar dezenas de indicadores em simultâneo, captar interações não-lineares entre fatores e gerar estimativas probabilísticas de risco para informar o agente no terreno.

Um dos trabalhos de referência é o estudo de Berk e Sorenson (2016), que desenvolveu um modelo de previsão de reincidência em violência doméstica para apoiar decisões judiciais em audiências de primeira instância numa grande área metropolitana dos Estados Unidos. O modelo foi treinado sobre cerca de 28 000 audiências com seguimento dos arguidos durante dois anos. Em cenários simulados, permitiu reduzir aproximadamente para metade a taxa de reincidência futura face à prática judicial não assistida [10]. Numa revisão integrativa mais recente, Hui,

Constantino e Lee (2023) organizam as aplicações de ML em violência doméstica em três grandes categorias: classificação de vítimas em alto risco, predição de novos episódios e exploração não supervisionada de padrões. Os autores discutem ainda os desafios metodológicos transversais [11]. Em trabalhos mais recentes, Grogger [36] examina especificamente o potencial da IA para reduzir a reincidência neste domínio, e Turner [37] aborda a equidade algorítmica em sistemas de avaliação de risco aplicados em contexto policial.

A literatura converge no uso de famílias de modelos relativamente comuns: regressão logística como linha de base interpretável, Random Forest e gradient boosting para captar relações não-lineares. Convergem também nas dificuldades: forte desequilíbrio entre classes, sensibilidade do modelo ao viés nos dados de treino e necessidade de garantir interpretabilidade e auditabilidade das decisões [37]. As preocupações éticas suscitadas por iniciativas anteriores noutros domínios da justiça criminal — em particular quanto à equidade entre grupos demográficos — reforçam a exigência de validação rigorosa antes de qualquer aplicação operacional.

2.5. Geração de Dados Sintéticos em Domínios Sensíveis

Em domínios com fortes restrições legais ou éticas — saúde, justiça criminal e, no caso do presente trabalho, processos de violência doméstica — o acesso a dados reais é geralmente lento ou bloqueado. No âmbito do projeto IA_PRVD_PT esteve prevista a colaboração com o Ministério da Administração Interna para acesso a dados anonimizados; mudanças internas no ponto de contacto institucional impediram que esse acesso se concretizasse durante o desenvolvimento deste trabalho. Perante este cenário, a geração de dados sintéticos surge como alternativa metodológica: permite treinar e comparar modelos, partilhar conjuntos reproduzíveis e contornar parte das limitações associadas à proteção de dados pessoais. A sua aplicabilidade está, naturalmente, condicionada pelo grau de fidelidade face às distribuições reais.

Numa revisão recente, Shi e colaboradores (2025) organizam as principais abordagens em três famílias: métodos estatísticos tradicionais (modelos paramétricos, redes Bayesianas), modelos generativos baseados em difusão e abordagens fundadas em large language models (LLMs) [14]. A linha de investigação em LLMs aplicados a dados tabulares foi inaugurada por Borisov e colaboradores (2023) com o sistema GReaT: modelos auto-regressivos geram registos sintéticos com propriedades estatísticas realistas e suportam geração condicionada em qualquer subconjunto de variáveis [12]. Em paralelo, Hegselmann e colaboradores (2023) apresentam o TabLLM: a serialização de dados tabulares em linguagem natural permite que LLMs realizem tarefas de classificação em regimes de poucos exemplos com desempenho competitivo face ao gradient boosting [13].

A aplicação destas abordagens a domínios sensíveis tem sido analisada em detalhe. Smolyak e colaboradores (2024) discutem as oportunidades e os riscos do uso de LLMs para gerar dados de

saúde sintéticos e identificam seis direções críticas de investigação. Entre essas direções, destacam-se a definição de métricas de avaliação adequadas, as questões de equidade entre subpopulações e o alinhamento regulamentar — pontos relevantes para qualquer aplicação em domínios de elevada sensibilidade social [15]. Em criminologia, o projeto SENSYN da Universidade de Leiden produz conjuntos de dados sintéticos para investigação em homicídio, com princípios FAIR e preservação da privacidade [16].

O presente trabalho posiciona-se neste quadro adotando uma abordagem híbrida. A geração programática dos dados é ancorada em fontes oficiais portuguesas, em particular o Relatório Anual de Segurança Interna, os dados trimestrais da Comissão para a Cidadania e a Igualdade de Género e as estatísticas da Associação Portuguesa de Apoio à Vítima. O recurso a um modelo de linguagem limita-se a uma função auxiliar na calibração de parâmetros e na proposta de estruturas de correlação plausíveis entre indicadores, sempre sujeitas a revisão humana posterior. Esta opção metodológica é desenvolvida em mais detalhe nos Capítulos 3 e 4.

2.6. Síntese e Posicionamento do Presente Trabalho

A revisão das secções anteriores permite traçar o quadro em que se insere este trabalho. A violência doméstica é em Portugal um problema social persistente, com cerca de 30 000 ocorrências anuais e fortes assimetrias entre denúncia, acusação e condenação, o que torna crítica a deteção precoce dos casos de maior risco. Desde julho de 2025, Portugal dispõe de um instrumento de avaliação de risco renovado, a RVD-R, embora a sua capacidade preditiva, usada isoladamente, seja apenas moderada, como mostra a meta-análise de Hanson e colaboradores. A literatura internacional mostra que o Machine Learning, quando bem desenhado, pode acrescentar valor preditivo a decisões análogas — o caso paradigmático é o de Berk e Sorenson (2016). Mas a aplicação a contextos sensíveis exige cuidado com interpretabilidade, equidade e auditoria humana.

É neste quadro que se insere o presente trabalho. Desenvolveu-se um pipeline reprodutível de classificação binária da reincidência sobre dados sintéticos calibrados a partir das estatísticas oficiais portuguesas (RASI, CIG e APAV), com três famílias de modelos comuns na literatura: Decision Tree, Random Forest e XGBoost. A novidade metodológica está na geração dos dados de treino — ancorada nas fontes nacionais e auxiliada por LLMs na proposta inicial de parâmetros e de estruturas de correlação, sempre com revisão humana. O âmbito limita-se à componente analítica e de modelação; o desenho do sistema operacional é desenvolvido em paralelo, no mesmo projeto.

3. Análise e Desenho da Solução

3.1. Visão Geral da Solução

O sistema desenhado neste capítulo corresponde a um pipeline analítico para a previsão de reincidência em violência doméstica a partir de avaliações estruturadas da ficha RVD-R. A solução recebe os dados de uma avaliação, transforma-os numa matriz de variáveis compatível com os modelos treinados, estima uma probabilidade de reincidência e associa essa previsão a uma explicação interpretável, variável a variável.

Importa clarificar que, no âmbito deste trabalho, a solução desenvolvida não constitui um sistema operacional completo para utilização em contexto policial ou institucional. O foco principal reside na componente de modelação preditiva, no pré-processamento dos dados, na avaliação experimental dos modelos e na interpretabilidade das previsões. A camada de serviço apresentada neste capítulo deve, por isso, ser entendida como um protótipo técnico mínimo de inferência, criado para demonstrar como o modelo poderia ser disponibilizado a uma aplicação externa em fases futuras do projeto.

Deste modo, ficam fora do âmbito desta entrega o desenvolvimento de uma interface final de apoio à decisão, a integração com sistemas reais das forças de segurança, a autenticação institucional em ambiente produtivo, a gestão de utilizadores e a validação operacional em contexto real. Esses elementos são considerados extensões futuras da iniciativa CITECA/ISTEC-Porto e dependem, necessariamente, de validação com dados reais e de enquadramento institucional próprio.

3.2. Análise de Requisitos

Os requisitos seguem uma estrutura uniforme, com categoria, identificador único (RF para funcionais, RNF para não-funcionais), nome, descrição, prioridade, estado, restrições e critério de verificação. Esta uniformidade torna cada requisito rastreável à camada da arquitetura que o concretiza e ao capítulo de testes que confirma o seu cumprimento.

3.2.1. Requisitos Funcionais

Os requisitos funcionais, identificados pela sigla RF, definem as funcionalidades que o sistema deve disponibilizar para cumprir os objetivos do projeto. No contexto deste trabalho, estes requisitos descrevem as operações essenciais associadas à ingestão dos dados da ficha RVD-R, à construção da variável-alvo, ao pré-processamento, ao treino e comparação de modelos, à avaliação do desempenho e à disponibilização de previsões acompanhadas de explicações interpretáveis.

A definição dos RF assume particular importância porque permite transformar os objetivos gerais do projeto em funcionalidades concretas, verificáveis e rastreáveis ao longo do desenvolvimento. Cada requisito funcional apresentado nesta secção inclui uma descrição do comportamento esperado, a sua prioridade, as restrições associadas e o respetivo critério de verificação, assegurando que a solução proposta não se limita a uma abordagem conceptual, mas corresponde a um sistema tecnicamente estruturado e passível de validação.

Categoria	Gestão de Dados
ID	RF-01
Nome do requisito	Ingestão de avaliações RVD-R
Descrição	O sistema deve carregar avaliações da ficha RVD-R a partir de ficheiros CSV, preservando as quatro categorias de resposta (S, N, N/A e S/I).
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• Conformidade com a estrutura da Portaria n.º 228/2025/1. • As respostas N/A e S/I não podem ser convertidas em valores ausentes — a ausência de informação é, ela própria, um sinal.
Verificação	Teste unitário sobre uma amostra de CSV, com verificação de tipos e da conservação das quatro categorias (Cap. 5).

Tabela 1 - RF Integração de Avaliações RVD-R

Categoria	Gestão de Dados
ID	RF-02
Nome do requisito	Construção da variável-alvo sem fuga de informação
Descrição	O sistema deve construir a variável-alvo de reincidência excluindo do conjunto de modelação o último episódio de cada agressor reincidente, preservando os episódios anteriores.
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• Um agressor é considerado reincidente quando tem mais do que um NUIPC associado. • Os episódios não-últimos não podem ser usados como exemplos trivialmente positivos.
Verificação	Comparação do AUC entre a configuração correta e a configuração ingénua (com fuga de informação), conduzida no Cap. 5 e no Cap. 6.

Tabela 2 - RF Construção da Variável-Alvo sem fuga de informação

Categoria	Processamento
ID	RF-03
Nome do requisito	Pipeline de pré-processamento reprodutível
Descrição	O sistema deve aplicar um pipeline reprodutível que faça a codificação tripla das respostas, o tratamento de valores ausentes e a derivação das variáveis agregadas.
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• A execução com a mesma seed deve produzir a mesma matriz de variáveis. • O pré-processamento é independente do modelo usado a jusante.
Verificação	Re-execução do notebook com seed fixa produz uma matriz idêntica; testes unitários sobre preprocess.py (Cap. 5).

Tabela 3 - RF Pipeline de pré-processamento reprodutível

Categoria	Processamento
ID	RF-04
Nome do requisito	Divisão treino/teste por agressor
Descrição	O sistema deve dividir os dados em treino (80%) e teste (20%) ao nível do agressor, garantindo que todos os episódios de um mesmo agressor ficam no mesmo conjunto.
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• A interseção de agressores entre treino e teste tem de ser vazia. • A divisão é estratificada pela reincidência do agressor.
Verificação	Verificação de que nenhum agressor aparece nos dois conjuntos e de que a proporção de reincidentes se mantém semelhante em ambos (Cap. 6).

Tabela 4 – RF Divisão treino/teste por agressor

Categoria	Modelação
ID	RF-05
Nome do requisito	Treino comparativo de modelos
Descrição	O sistema deve treinar e comparar três famílias de classificadores: árvore de decisão, Random Forest e XGBoost.
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• Os três modelos são treinados sobre exatamente as mesmas variáveis. • A comparação cobre o espectro interpretável, ensemble e boosting.
Verificação	A tabela de comparação de modelos (Cap. 6) reporta os três classificadores com o conjunto completo de métricas.

Tabela 5 - RF Treino comparativo de modelos

Categoria	Modelação
ID	RF-06
Nome do requisito	Afinação automática de hiperparâmetros
Descrição	O sistema deve afinar os hiperparâmetros de cada modelo por otimização Bayesiana (Optuna), usando validação cruzada agrupada por agressor (GroupKFold, k=5).
Prioridade	4 — Importante
Estado	Fixo
Restrições	• O agrupamento por agressor impede fuga de informação durante a validação. • A afinação substitui o ajuste manual subjetivo.
Verificação	Execução das tentativas Optuna por modelo; os hiperparâmetros ótimos são reportados em tabela própria (Cap. 6).

Tabela 6 - RF Afinação automática de hiperparâmetros

Categoria	Avaliação
ID	RF-07
Nome do requisito	Avaliação com métricas adequadas e análise por subgrupo
Descrição	O sistema deve avaliar cada modelo por AUC-ROC, AUC-PR, sensibilidade, precisão e F1, e reportar o desempenho decomposto por tipologia de violência (C1, C2, C3 e OUTRA).
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• Em classes desequilibradas, a sensibilidade tem prioridade pelo custo dos falsos negativos. • A leitura por subgrupo serve para detetar diferenças de desempenho entre subpopulações.
Verificação	As tabelas de métricas e de AUC por tipologia (Cap. 6) reportam todas as métricas e a decomposição por subgrupo.

Tabela 7 - RF Avaliação com métricas adequadas e análise por subgrupo

Categoria	Interpretabilidade
ID	RF-08
Nome do requisito	Explicação das previsões (XAI global e local)
Descrição	O sistema deve calcular a importância das variáveis a nível global (importância intrínseca e SHAP) e produzir, para cada previsão, a explicação local correspondente (gráfico de cascata).
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• A explicação acompanha sempre a previsão: nenhuma decisão é entregue sem justificação variável a variável. • Aplica-se TreeSHAP ao modelo retido para a camada de serviço.
Verificação	As figuras SHAP (global e por caso) e a função de previsão com explicação demonstram o requisito (Cap. 6).

Tabela 8 - RF Explicação das previsões (XAI global e local)

Categoria	Serviço
ID	RF-09
Nome do requisito	Serviço de inferência com validação clínica
Descrição	O sistema deve expor a previsão num endpoint HTTP POST /prever que valida cinco regras de coerência clínica antes da inferência e devolve, num único contrato JSON, a probabilidade, o nível de risco e as contribuições SHAP por variável.
Prioridade	3 — Desejável
Estado	Aberto
Restrições	• Pedidos que violem as regras de coerência clínica são rejeitados com HTTP 422. • O acesso ao endpoint exige autenticação por token.
Verificação	Testes de integração e de sistema sobre os endpoints /saude e /prever, incluindo coerência clínica e autenticação (Cap. 5).

Tabela 9 - RF Serviço de inferência com validação clínica

3.2.2. Requisitos Não-Funcionais

Os requisitos não-funcionais, identificados pela sigla RNF, definem as características de qualidade que o sistema deve respeitar, independentemente das funcionalidades concretas que disponibiliza. Enquanto os requisitos funcionais descrevem o que o sistema deve fazer, os RNF estabelecem as condições em que essas funcionalidades devem ser executadas, abrangendo aspetos como reprodutibilidade, interpretabilidade, conformidade regulamentar, equidade, portabilidade e segurança.

No presente projeto, estes requisitos assumem especial relevância devido à natureza sensível do domínio em análise. A previsão de reincidência em violência doméstica envolve informação potencialmente crítica e decisões com impacto social significativo, pelo que o sistema deve ser concebido como uma ferramenta de apoio à decisão humana, transparente, auditável e tecnicamente robusta. Assim, os RNF apresentados nesta secção procuram garantir que a solução desenvolvida não privilegia apenas o desempenho preditivo, mas também a responsabilidade, a fiabilidade e a adequação ética da sua utilização.

Categoria	Qualidade
ID	RNF-01
Nome do requisito	Reprodutibilidade
Descrição	Toda a cadeia (geração, pré-processamento, treino e avaliação) deve produzir resultados idênticos quando executada com a mesma seed e as mesmas versões das bibliotecas.
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• Seeds explícitas (random_state=42) em todas as funções estocásticas. • Versões das bibliotecas fixadas em requirements.txt.
Verificação	Re-execução em ambiente limpo reproduz as tabelas e figuras (Cap. 4 e Anexo C).

Tabela 10 - RNF Reprodutibilidade

Categoria	Qualidade
ID	RNF-02
Nome do requisito	Interpretabilidade operacional
Descrição	Cada previsão deve ser acompanhada de uma explicação compreensível por um não-especialista: tabela de contribuições SHAP com magnitude, direção e descrição clínica em português.
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• A descrição clínica de cada item é obtida de um dicionário documentado no Anexo B. • A interpretabilidade é requisito de desenho, não acessório posterior.
Verificação	A função de previsão com explicação e o endpoint /prever devolvem a explicação legível (Cap. 4).

Tabela 11 - RNF Interpretabilidade operacional

Categoria	Conformidade
ID	RNF-03
Nome do requisito	Conformidade regulamentar (Regulamento de IA e RGPD)
Descrição	O sistema deve enquadrar-se como apoio à decisão humana (Art. 5(1)(d) do Regulamento de IA da UE) e respeitar os artigos 9 e 22 do RGPD; durante o desenvolvimento, todo o trabalho assenta em dados sintéticos.
Prioridade	5 — Essencial
Estado	Fixo
Restrições	• O sistema não toma decisões autónomas: o profissional mantém a decisão final. • Não há tratamento de dados pessoais reais na fase académica.
Verificação	O mapeamento das exigências regulamentares à arquitetura é apresentado nos Cap. 3.6 e 7.5.

Tabela 12 - RNF Conformidade regulamentar (Regulamento de IA e RGPD)

Categoria	Equidade
ID	RNF-04
Nome do requisito	Equidade entre subgrupos
Descrição	O desempenho do modelo retido deve manter-se aproximadamente estável entre tipologias de violência, com variação de AUC inferior a 0,05 entre o melhor e o pior subgrupo.
Prioridade	4 — Importante
Estado	Fixo
Restrições	Diferenças sistemáticas entre subgrupos seriam fonte de injustiça operacional.
Verificação	Cálculo da variação de AUC entre subgrupos a partir da tabela de AUC por tipologia, confirmando se se mantém abaixo do limiar de 0,05 (Cap. 6).

Tabela 13 - RNF Equidade entre subgrupos

Categoria	Portabilidade
ID	RNF-05
Nome do requisito	Portabilidade e custo zero
Descrição	O sistema deve correr em qualquer máquina com Python 3.10+ e as dependências de requirements.txt, sem infraestrutura comercial e sem custos de licenciamento.
Prioridade	4 — Importante
Estado	Fixo
Restrições	- Todas as bibliotecas são de código aberto e utilização gratuita. - Não há dependência de hardware especializado (GPU).
Verificação	Instalação limpa com <code>pip install -r requirements.txt</code> reproduz todo o pipeline (Anexo C).

Tabela 14 - RNF Portabilidade e custo zero

Categoria	Segurança
ID	RNF-06
Nome do requisito	Segurança da camada de serviço
Descrição	O endpoint POST /prever deve exigir autenticação por Bearer token, com comparação resistente a ataques de temporização.
Prioridade	3 — Desejável
Estado	Aberto
Restrições	• Mesmo em ambiente sintético, o serviço modela as garantias mínimas exigíveis em produção.
Verificação	secrets.compare_digest em api.py; um token errado devolve HTTP 401 (teste de autenticação, Cap. 5).

Tabela 15 - RNF Segurança da camada de serviço

3.3. Arquitetura do Sistema

A solução desenhada para o problema descrito no Capítulo 1 organiza-se como um pipeline analítico em quatro camadas — dados, pré-processamento, modelação e serviço — que percorrem o ciclo completo desde a aquisição de uma avaliação RVD-R até à entrega de uma probabilidade de reincidência ao agente, acompanhada da respetiva explicação. Cada camada cumpre uma responsabilidade única e expõe uma interface estável, o que permite substituir qualquer componente (por exemplo, trocar o gerador sintético pela ligação a uma base operacional) sem alterar as restantes.

Esta organização decorre de três condicionantes específicas do domínio. Primeira: em violência doméstica, um falso negativo tem custo social muito superior ao de um falso positivo, pelo que a sensibilidade ganha prioridade sobre a precisão pontual. Segunda: o sistema apoia profissionais no terreno e não os substitui, o que torna a interpretabilidade e a auditabilidade das decisões pesos de primeira ordem na seleção do modelo. Terceira: pela sensibilidade dos dados reais e pela impossibilidade prática de os obter no horizonte desta entrega, todo o trabalho assenta sobre um conjunto sintético, condição que se reflete diretamente no desenho de várias camadas.




Figura 1: Arquitetura do sistema em quatro camadas: o fluxo de uma avaliação RVD-R desde a ingestão dos dados, pelo pré-processamento e pela modelação, até à entrega da previsão explicada ao profissional na camada de serviço.

3.3.1. Camadas funcionais

A arquitetura proposta organiza-se em quatro camadas funcionais, alinhadas com o fluxo de processamento de uma avaliação RVD-R desde a entrada de dados até à apresentação da previsão ao agente.

A camada de dados é responsável pela aquisição e persistência do conjunto de modelação. No âmbito do presente trabalho, esta camada alimenta-se de um gerador de dados sintéticos calibrado contra estatísticas oficiais (RASI, APAV, PAVD) e assistido por um Large Language Model na definição de distribuições e correlações. No horizonte do projeto, esta camada será substituída

por uma integração direta com as bases SIGO e SGI, sem alteração das interfaces das camadas seguintes.

A camada de pré-processamento converte o registo bruto numa matriz de variáveis prontas para o modelo. Inclui validação tipológica, tratamento de respostas Não Aplicável e Sem Informação como categorias informativas, codificação tripla (afirmativa, NA, SI) de cada item RVD-R e construção de variáveis agregadas — scores por secção, índices de cluster (violência física, controlo coercivo, instabilidade, letalidade) e termos de interação documentados na literatura.

A camada de modelação aloja três classificadores supervisionados treinados sobre as mesmas variáveis: Decision Tree, Random Forest e XGBoost. A afinação de hiperparâmetros é conduzida com Optuna sobre validação cruzada agrupada por agressor (GroupKFold, $k=5$), o que impede a contaminação entre folds quando o mesmo agressor tem múltiplos episódios. Desta camada emerge o modelo retido para serviço operacional, selecionado por critério multi-eixo (desempenho, interpretabilidade, estabilidade) descrito em 3.6.

A camada de serviço expõe o modelo treinado e a sua explicação ao consumidor final. Concretiza-se num serviço HTTP mínimo (FastAPI + Pydantic) que recebe uma avaliação RVD-R válida, valida cinco regras de coerência clínica, devolve a probabilidade prevista, a classe operacional (Residual, Moderada, Grave) e a respetiva explicação SHAP num único contrato JSON.

3.3.2. Drivers arquiteturais

Cada uma das três condicionantes de domínio traduz-se em decisões arquiteturais concretas.

A prioridade à sensibilidade impede que a seleção do modelo operacional se resuma ao AUC. Em linha com Rudin [47], a interpretabilidade e a estabilidade das explicações pesam tanto como o desempenho preditivo no critério multi-eixo descrito em 3.6.

A auditabilidade impõe duas separações claras na arquitetura. O pré-processamento é isolado dos modelos, o que permite testar o pipeline com qualquer classificador. E cada previsão produzida pela camada de serviço é acompanhada da sua explicação SHAP, garantindo que nenhuma decisão é entregue ao utilizador sem justificação variável a variável.

A natureza sintética dos dados condiciona dois aspetos. Primeiro, a validação dos modelos é feita com cross-validation agrupada por agressor (GroupKFold) — único modo de impedir a fuga de informação entre episódios do mesmo indivíduo. Segundo, o gerador e os prompts são documentados de forma exaustiva, para que a metodologia possa ser replicada sobre dados reais no futuro.

3.4. Tecnologias e Bibliotecas Seleccionadas

A implementação assenta em bibliotecas Python de código aberto. A geração e o pré-processamento dos dados utilizam `numpy` para amostragem e álgebra vetorial e `pandas` para a manipulação tabular. A modelação é conduzida com `scikit-learn` [44], que disponibiliza implementações dos algoritmos seleccionados, dos componentes de pipeline e das métricas de avaliação. O classificador `XGBoost` é fornecido pela biblioteca homónima `xgboost` [17] e a afinação de hiperparâmetros é conduzida com `optuna` [18]. A interpretabilidade é calculada com `shap`, que implementa o algoritmo `TreeSHAP` [19], [20]. Para visualização recorre-se a `matplotlib` e `seaborn`. O ambiente de execução é o Jupyter Notebook.

A camada de serviço, que expõe o modelo treinado para consumo por aplicações externas, utiliza `fastapi` como framework HTTP, `pydantic` para validação estrutural dos pedidos e `joblib` para a serialização do artefacto do modelo.

Todas as bibliotecas escolhidas são de utilização gratuita e estão amplamente documentadas, condições necessárias à reprodutibilidade do trabalho.

3.5. Conjunto de Dados Sintéticos

O conjunto de dados utilizado neste trabalho foi gerado sinteticamente em virtude das restrições legais ao acesso a dados reais da ficha RVD-R, que contém informação pessoal sensível e cujo tratamento requer protocolos específicos com as forças de segurança e a Comissão Nacional de Protecção de Dados. A geração foi calibrada com base em fontes oficiais portuguesas e em literatura empírica, e a sua estrutura segue a organização da ficha RVD-R aprovada pela Portaria n.º 228/2025/1 [6].

3.5.1. Caracterização da ficha RVD-R

A ficha RVD-R organiza-se em três blocos principais. A secção A reúne os fatores associados ao agressor, incluindo antecedentes de queixas e denúncias (A1), incumprimento de ordens judiciais (A2), consumo excessivo de álcool ou drogas (A3), instabilidade financeira ou laboral (A4), impulsividade ou dificuldades de autocontrolo (A5) e tentativa ou ameaça de suicídio (A6). A secção B descreve o incidente e a severidade da violência, com nove itens que cobrem violência física (B1), estrangulamento ou sufocação (B2), aumento de frequência ou gravidade (B3), uso ou ameaça de uso de arma (B4), ameaça ou tentativa de morte (B5), violência sexual (B6), conflitos familiares (B7), dependência entre vítima e agressor (B8) e isolamento da vítima (B9). A secção C avalia a vulnerabilidade da vítima e diferencia-se em três tipologias: C1 (relações de intimidade), C2 (violência filio-parental, sobre crianças e jovens) e C3 (violência contra idosos) [7]. O nível de risco resultante (baixo, médio ou elevado) é obtido a partir da soma ponderada das respostas, com pesos pré-definidos para os itens com maior valor preditivo identificado pela investigação.

3.5.2. Fontes para calibração

Cinco famílias de fontes foram utilizadas como referência para calibrar as distribuições do gerador. Os Relatórios Anuais de Segurança Interna fornecem o volume anual de ocorrências e o número de homicídios em contexto de violência doméstica [1]. Os boletins trimestrais da CIG informam sobre os desfechos judiciais, em particular as taxas de arquivamento e de acusação [3]. As estatísticas da APAV contribuem com os perfis demográficos das vítimas e dos agressores e com a proporção de casos de violência repetida [2]. O estudo da Faculdade de Direito da Universidade do Porto sobre homicídio conjugal [8] e o relatório do Ministério Público sobre os homicídios de 2023 fornecem a ordem relativa de fatores de risco em contextos de letalidade [21]. Por fim, a sistematização de Morais-Gonçalves e colaboradores ancora a seleção dos fatores com fundamentação empírica para a predição de reincidência [9].

3.5.3. Geração assistida por LLM

A geração de dados está implementada em Python e organiza-se em quatro fases sequenciais:

- Fase 1 — Atribuição de um perfil de risco latente a cada agressor, sorteado de uma distribuição Beta bimodal que reflete o quadro empírico português: cerca de 70% dos casos numa componente de risco mais baixo (consistente com a predominância de ameaça e coação reportada pela APAV) e 30% numa componente de risco mais elevado (consistente com a minoria de casos de violência grave reportados pelo Ministério Público).
- Fase 2 — Geração das respostas aos itens da ficha em função do perfil latente, com cada item caracterizado por uma probabilidade base e uma sensibilidade ao perfil de risco.
- Fase 3 — Aplicação de clusters de amplificação que reproduzem co-ocorrências documentadas na literatura, como a associação entre violência prévia, escalação e uso de arma.
- Fase 4 — Determinação da probabilidade de reincidência a partir do perfil latente e dos bónus observados em itens-chave (A1, A5, B3, B7), refletindo a hierarquia de fatores identificada pelo Ministério Público em 2023.

O recurso a um LLM limitou-se a três funções auxiliares: proposta inicial de probabilidades marginais por item, sugestão de estruturas de correlação plausíveis entre indicadores (clusters de amplificação) e triagem das fontes bibliográficas relevantes para cada parâmetro. Todas as sugestões passaram por revisão humana, sendo aceites apenas quando confirmáveis numa fonte oficial ou na literatura empírica. Esta divisão de tarefas alinha-se com a investigação sobre LLMs como assistentes de geração tabular [12], [13], [14] e reconhece explicitamente os riscos identificados pela literatura sobre dados sensíveis [15], mantendo o investigador como validador final.

3.5.4. Validação dos dados sintéticos

A validação dos dados sintéticos foi conduzida em três níveis, cada um a verificar uma propriedade diferente.

O primeiro é o nível marginal. Para cada item da ficha, comparou-se a frequência observada de cada resposta no conjunto gerado com a estatística-alvo derivada das fontes oficiais (RASI, APAV, PAVD). Este teste mostra que as proporções univariadas que o relatório esperava encontrar no terreno estão presentes nos dados gerados — sem este patamar, o conjunto sintético seria desde logo inutilizável.

O segundo é o nível de coerência interna. Verificou-se que a soma ponderada das respostas reproduz a classificação de risco esperada pelo próprio instrumento RVD-R, e que as regras impostas ao gerador (monotonicidade entre itens relacionados, propriedade stateful das respostas ao longo da ficha, limites superiores e inferiores de probabilidade) são respeitadas em todas as instâncias. Este nível garante que o conjunto não viola a lógica do instrumento.

O terceiro é o nível das correlações induzidas. Examinaram-se as associações entre os itens-trigger e os itens-alvo dos clusters de amplificação (por exemplo, agressores com histórico de ameaças graves devem apresentar maior probabilidade de uso de armas). Confirmou-se que estes padrões multivariados são detetáveis pelo pipeline de análise — condição necessária para que a tarefa de modelação tenha sinal genuíno e não ruído.

Reconhece-se, no entanto, que a fiabilidade dos dados sintéticos é limitada por construção: os modelos treinados sobre eles servem para validar a metodologia, e a transferibilidade para dados reais permanece como trabalho futuro.

3.6. Desenho do Pipeline de Pré-processamento

O pipeline de pré-processamento converte o ficheiro CSV gerado num conjunto de variáveis adequadas ao treino dos modelos supervisionados. É composto por quatro etapas sucessivas: ingestão por lotes do ficheiro, limpeza e validação dos registos, codificação e construção de variáveis agregadas, e divisão estratificada em conjuntos de treino e teste. Cada etapa é encapsulada em componentes reutilizáveis do scikit-learn de modo a assegurar a reprodutibilidade e a permitir a integração futura com outros conjuntos de dados.

3.6.1. Ingestão batch

A ingestão dos dados é simulada como um processo batch, em que o ficheiro CSV é lido em blocos sucessivos através do parâmetro `chunksize` da função `pandas.read_csv`. Esta opção, embora não estritamente necessária para o volume atual (cerca de 30 000 registos), é justificada pelos requisitos de escalabilidade exigida em fases futuras, em que se prevê o tratamento de volumes

muito superiores quando os dados reais estiverem disponíveis. A leitura preserva todas as respostas literais, incluindo o valor textual N/A, que de outro modo seria silenciosamente convertido em valor ausente pela configuração predefinida do pandas.

3.6.2. Limpeza e validação

A etapa de limpeza assegura a coerência tipológica do conjunto, valida a integridade dos identificadores (NUIPC, agressor, vítima) e aplica regras de coerência sobre os campos derivados, em particular a verificação de que a classificação de risco atribuída corresponde à soma ponderada das respostas. Os valores ausentes são tratados de forma diferenciada: respostas explícitas como Não Aplicável (N/A) ou Sem Informação (S/I) são preservadas como categorias informativas, enquanto valores omissos técnicos são imputados ou descartados consoante a sua origem.

3.6.3. Codificação e feature engineering

A codificação adotada preserva a informação sobre o nível de conhecimento disponível no momento da avaliação. Cada item principal das secções A e B gera três indicadores binários: um para a resposta afirmativa (sufixo `_S`), um para a resposta Não Aplicável (`_NA`) e um para a resposta Sem Informação (`_SI`). Esta tripla codificação permite que os modelos captem padrões não apenas no conteúdo das respostas, mas também no perfil de informação reportado, hipótese metodologicamente relevante porque a ausência de informação pode, ela própria, ser um sinal. Sobre esta base, são construídas variáveis agregadas: os scores por secção (A, B e total), indicadores de cluster temático (violência física, controlo coercivo, instabilidade, letalidade), termos de interação entre pares de itens documentados como co-ocorrentes na literatura, contagens do nível de informação disponível e a tipologia de violência codificada em variáveis indicadoras.

3.6.4. Tratamento do desequilíbrio entre classes

Sendo a reincidência uma classe minoritária, é necessário compensar o desequilíbrio entre exemplos positivos e negativos durante o treino. Foram consideradas três estratégias: a atribuição de pesos inversamente proporcionais à frequência das classes (parâmetro `class_weight=balanced`), a sobreamostragem sintética da classe minoritária pelo método SMOTE, e a subamostragem aleatória da classe maioritária. A estratégia adotada como linha de base é a primeira, por ser computacionalmente leve, manter a totalidade dos dados originais e ser facilmente combinável com qualquer modelo do scikit-learn. As restantes estratégias ficam disponíveis como opção de comparação na fase de validação.

3.7. Desenho da Solução de Modelação

Usámos três famílias de classificadores supervisionados, escolhidas pelos seus papéis distintos. Decision Tree estabelece uma linha de base diretamente interpretável; Random Forest [43] capta interações não-lineares entre variáveis e produz estimativas robustas de importância; XGBoost [17] permite comparar uma fronteira de decisão mais complexa. A escolha destas três famílias segue o plano de trabalho do projeto IA_PRVD_PT [10], [11], [22].

A escolha do modelo a colocar em produção não depende só do desempenho preditivo. Em decisões de alto risco — categoria em que o presente sistema se enquadra ao abrigo do Anexo III(6) do Regulamento de IA da UE [38] — pesam também a estabilidade das estimativas de importância ao longo de reamostragens, a robustez face a pequenas alterações nos dados de treino e o grau de interpretabilidade global e local. Este critério multi-eixo segue o argumento de Rudin a favor de modelos interpretáveis por construção quando o impacto humano das decisões é significativo [47], argumento que se alinha com as exigências de transparência e supervisão humana impostas pelo próprio Regulamento de IA aos sistemas classificados como de alto risco. Na prática, o modelo operacional pode não ser o de maior AUC-ROC, desde que essa decisão esteja justificada pelos critérios anteriores.

3.7.1. Modelos candidatos e afinação de hiperparâmetros

Os três modelos retidos correspondem a níveis crescentes de complexidade. O Decision Tree é um classificador que parte os dados sucessivamente por testes binários sobre cada variável, formando uma estrutura em árvore; cada folha contém uma classe. É o modelo mais simples e o único totalmente transparente — qualquer previsão pode ser explicada listando as decisões binárias ao longo do caminho. Em contrapartida, é instável (pequenas alterações nos dados podem alterar muito a árvore) e tende a memorizar o conjunto de treino, o que lhe limita a capacidade de generalização.

O Random Forest [43] mitiga esta limitação treinando centenas de árvores em subconjuntos diferentes dos dados e das variáveis, e combinando as suas previsões por votação. O efeito de média estabiliza o classificador e reduz a sobreaprendizagem, ao custo de perder a transparência da árvore individual. Continua, no entanto, a permitir cálculo direto da importância de cada variável e é compatível com explicações TreeSHAP exatas.

O XGBoost [17] adota uma estratégia diferente: em vez de treinar árvores independentes, treina-as em sequência, em que cada nova árvore tenta corrigir os erros das anteriores (gradient boosting). É frequentemente o modelo de melhor desempenho preditivo em conjuntos tabulares de dimensão moderada, mas a sua fronteira de decisão é menos interpretável e mais sensível à configuração de hiperparâmetros.

Os hiperparâmetros de cada modelo não são fixados manualmente: são afinados por otimização Bayesiana com a biblioteca Optuna [18], que implementa o sampler Tree-structured Parzen Estimator (TPE). Para cada modelo é definido um espaço de procura sobre os hiperparâmetros mais relevantes (profundidade, número de estimadores, regularização, taxa de aprendizagem, fração de subamostragem) e é executado um número fixo de tentativas (cinquenta por modelo na configuração de produção). O objetivo otimizado é a área sob a curva ROC, calculada por validação cruzada interna ao conjunto de treino. Os melhores hiperparâmetros são depois usados para treinar o modelo final, que é avaliado uma única vez no conjunto de teste reservado.

3.7.2. Estratégia de validação

A divisão entre treino e teste é estratificada em 80% e 20% e é realizada ao nível do agressor, de modo a evitar fuga de informação entre conjuntos: todos os episódios de um mesmo agressor ficam todos em treino ou todos em teste. A estratificação é aplicada sobre o valor máximo da variável-alvo por agressor, preservando a proporção de casos com pelo menos uma reincidência. Para a otimização de hiperparâmetros, é aplicada validação cruzada com GroupKFold (cinco folds), que respeita a mesma restrição de agrupamento por agressor durante a validação interna. Esta abordagem é mais conservadora do que uma simples validação cruzada estratificada porque elimina a possibilidade de o modelo memorizar padrões de agressores específicos vistos em treino e aplicá-los aos mesmos agressores em teste.

3.7.3. Métricas de avaliação

Em conjuntos com classes desequilibradas, a accuracy pura é enganadora: um classificador trivial que escolhe sempre a classe maioritária pode atingir valores aparentemente elevados. Por isso, avaliamos o desempenho com um conjunto de cinco métricas complementares, cada uma com uma leitura própria.

A precisão (precision) mede a proporção de positivos previstos que são verdadeiramente positivos; responde à pergunta «quando o modelo diz que vai reincidir, com que frequência tem razão?». A sensibilidade ou recall mede a proporção de positivos reais que o modelo capta; responde à pergunta «de todos os agressores que vão reincidir, quantos é que o modelo deteta?». São métricas em tradeoff: subir o limiar de classificação aumenta a precisão e baixa a sensibilidade, e vice-versa. O F1-score é a média harmónica das duas, útil para resumir o equilíbrio num único valor.

A área sob a curva ROC (AUC-ROC) [45] mede a capacidade do modelo para ordenar corretamente um par aleatório de exemplos — um positivo e um negativo — pelas suas probabilidades estimadas. Tem a vantagem de ser independente do limiar de decisão e de variar entre 0,5 (acaso) e 1,0 (separação perfeita). A área sob a curva precisão-sensibilidade (AUC-PR) é uma alternativa

que, em conjuntos com classes desequilibradas, é mais informativa do que o AUC-ROC porque reflete diretamente a deteção da classe minoritária [46].

Em violência doméstica, a sensibilidade é a métrica prioritária: o custo social de um falso negativo (não sinalizar um agressor que viria a reincidir) é desproporcionalmente superior ao de um falso positivo. Por essa razão, ainda que reportemos todas as métricas, é a sensibilidade que orienta a seleção do limiar operacional e a comparação entre modelos. A análise cobre tanto o conjunto global como cada tipologia (C1, C2, C3 e OUTRA), para detetar diferenças de desempenho entre subpopulações que de outro modo ficariam ocultas pela média global.

3.7.4. Interpretabilidade dos modelos

A interpretabilidade dos modelos faz parte do desenho da solução e não é um acessório posterior. Esta opção responde simultaneamente a duas exigências. A primeira é regulamentar: o Regulamento de IA da UE classifica os sistemas de apoio à aplicação da lei como de alto risco e exige, no Anexo III(6) e nos Artigos 13 e 14, transparência sobre o funcionamento, documentação técnica e mecanismos efetivos de supervisão humana — requisitos que pressupõem que as decisões do modelo possam ser auditadas [38]. A segunda é metodológica: Rudin argumenta que, em decisões de alto risco, modelos transparentes por construção são preferíveis a explicações pós-hoc sobre modelos opacos [47]. Os dois argumentos convergem: a interpretabilidade não é uma cortesia ao utilizador final mas uma condição para o cumprimento da norma e para a defensabilidade da decisão informada por ML.

Sobre o modelo retido para a camada operacional aplicam-se valores de Shapley calculados pelo TreeSHAP [19], [20], que devolve atribuições exatas para o modelo treinado. A análise é feita a três níveis: a importância média absoluta por variável, que dá uma visão global do impacto de cada indicador; a distribuição dos valores SHAP por amostra (gráfico de enxame), que mostra direção e magnitude das contribuições; e a análise individual das previsões em casos representativos (gráfico de cascata), que permite ver a justificação atribuída a uma decisão concreta. Os resultados são depois confrontados com a importância intrínseca dos modelos de árvores e com os fatores priorizados pela literatura portuguesa, e a concordância entre os dois métodos é tomada como um dos critérios de seleção do modelo operacional.

3.7.5. Níveis de risco operacionais

A probabilidade estimada pelo classificador é traduzida, para efeito de leitura operacional, numa escala de três níveis. Esta escala simplifica a comunicação da previsão a quem não está familiarizado com saídas probabilísticas e aproxima-se da estrutura tripartida do próprio instrumento RVD-R (baixo, médio, elevado):

- Risco Residual: probabilidade estimada inferior a 33%, situações em que se espera baixa probabilidade de novo episódio, ainda que se recomende manter a vigilância;
- Risco Moderado: probabilidade entre 33% e 66%, situações intermédias que justificam monitorização ativa e reavaliação do plano de segurança;
- Risco Elevado: probabilidade superior a 66%, situações em que se recomenda o acionamento imediato de medidas de proteção.

Os cortes a 33% e 66% dividem o intervalo de probabilidades em três terços iguais. Esta convenção é integrada na função de previsão com explicação descrita no Capítulo 4.

Os níveis de risco operacionais definidos neste trabalho resultam da discretização da probabilidade estimada pelo modelo em três categorias: risco residual, risco moderado e risco grave. Para efeitos exploratórios, foram utilizados os limiares 0,33 e 0,66, permitindo distinguir previsões de baixa, média e elevada probabilidade estimada de reincidência.

Importa, contudo, salientar que estes limiares não devem ser interpretados como valores finais para utilização operacional. A sua adoção tem apenas uma função demonstrativa no contexto do protótipo desenvolvido, permitindo testar a forma como uma previsão probabilística pode ser convertida numa classificação compreensível para o utilizador final. A definição de limiares operacionais definitivos exigiria validação posterior com dados reais, análise de calibração das probabilidades e participação de especialistas do domínio, de modo a ajustar os cortes em função do equilíbrio pretendido entre sensibilidade, precisão e custo dos falsos negativos.

Num domínio como a violência doméstica, em que os falsos negativos podem ter consequências particularmente graves, a escolha dos limiares deve privilegiar a deteção de potenciais reincidentes, mesmo que isso implique aceitar um maior número de falsos positivos. Assim, os valores utilizados neste trabalho devem ser entendidos como uma primeira aproximação metodológica e não como uma recomendação operacional definitiva.

4. Desenvolvimento do Projeto

4.1. Processo de Desenvolvimento

O desenvolvimento seguiu uma metodologia iterativa em ciclos curtos. Cada fase — geração de dados, análise exploratória, pré-processamento, modelação, avaliação — foi tratada em ambiente interativo, com versionamento Git ao longo de todas as iterações.

A modelação evoluiu em três iterações sucessivas, cada uma responsável por uma decisão de desenho.

A primeira iteração restringia o treino à primeira avaliação de cada agressor, definindo a variável-alvo como reincidência futura. Produziu um AUC próximo do acaso sobre o gerador v1, revelando ausência de sinal preditivo nesse conjunto e motivando o investimento na próxima versão do gerador.

A segunda iteração incluía todos os episódios disponíveis, mas inflacionava artificialmente as métricas: os episódios de ordem superior são, por construção, sempre positivos para a variável-alvo, o que correspondia a uma fuga de informação grave entre treino e teste.

A iteração final, descrita nas secções seguintes, remove apenas o último episódio dos agressores reincidentes e preserva todos os anteriores e a totalidade dos não reincidentes. A pergunta passa a ser, para cada avaliação observada, se existirá pelo menos mais um episódio registado a seguir — uma formulação que não sofre da inflação anterior nem do silêncio total da primeira.

4.2. Implementação da Geração de Dados Sintéticos

4.2.1. Estrutura do gerador

O gerador de dados sintéticos é implementado no script `dados/gerar_rvd11_v3.py`. A arquitetura segue as quatro fases descritas no Capítulo 3 e é configurada por dois dicionários principais. O dicionário `FEATURE_PARAMS` associa a cada item das secções A e B um par de valores (probabilidade base, sensibilidade) que define a função sigmóide de geração. O dicionário `CLUSTER_BOOSTS` codifica as correlações entre variáveis através de pares (item-trigger, itens-alvo, magnitude do bónus). A distribuição das tipologias C1, C2, C3 e OUTRA segue o vetor `TPOLOGY_PROBS` (com 70% para C1, consistente com a predominância das relações de intimidade nos dados oficiais), e o dicionário `TPOLOGY_ADJUSTMENTS` refina as probabilidades de itens específicos por tipologia. A reprodutibilidade é assegurada pela aceitação de uma seed explícita como argumento de linha de comandos.

4.2.2. Diálogo com o LLM e iteração dos parâmetros

A interação com o LLM foi formalizada como ciclo iterativo de calibração, repetido para cada item da ficha, em três passos:

- Pedido em linguagem natural pelo investigador: descreve o item, identifica as fontes oficiais relevantes e solicita uma sugestão inicial de probabilidade base e sensibilidade.
- Resposta do LLM: sugestão acompanhada de justificação ancorada nas fontes fornecidas.
- Validação humana: o investigador consulta a fonte e decide. Aceita quando a estatística é confirmável, ajusta quando a sugestão se afasta da evidência, rejeita quando a fonte não suporta a proposta.

Os ciclos repetem-se até convergência. A abordagem alinha-se com as boas práticas identificadas na literatura sobre LLMs como assistentes de geração tabular [12], [13] e mantém o investigador como validador final, em linha com os princípios de explicabilidade e equidade discutidos por Smolyak e colaboradores [15].

4.2.3. Calibração com estatísticas oficiais

Cada parâmetro do gerador está ancorado, na medida do possível, a uma estatística verificável. A título de exemplo, a probabilidade base de respostas afirmativas no item A1 (antecedentes de violência) é fixada em valor reduzido para refletir o predomínio de casos sem registo, enquanto a sensibilidade ao perfil de risco é elevada para reproduzir a presença de violência prévia em aproximadamente metade dos casos analisados pelo estudo da Universidade do Porto sobre homicídio conjugal [8]. A sensibilidade do item A5 (escalação) foi fixada num valor ainda mais alto porque a literatura nacional identifica a escalação como o segundo fator de risco mais frequente nos homicídios em violência doméstica. As taxas de reincidência por tipologia estão calibradas com a evidência disponível, com o programa PAVD a fornecer a referência inferior de 22,7% para a reincidência criminal e a APAV a fornecer um limite superior de 53,4% para os casos de violência repetida [4], [2]. Os bónus observados na fase de atribuição da reincidência seguem a ordem dos fatores reportada pelo Ministério Público nos homicídios de 2023 [21].

4.2.4. Validação pós-geração

A validação pós-geração é realizada num notebook dedicado que comprova, primeiro, a fiabilidade marginal das distribuições às estatísticas-alvo e, segundo, a coerência das correlações induzidas pelos clusters. Na versão consolidada do gerador (v3), a taxa global de reincidência simulada é de 29,6% sobre 22 500 agressores únicos, valor que se enquadra entre as referências empíricas de 22,7% para a reincidência criminal estrita do PAVD [4] e 53,4% para o conjunto mais amplo de vitimação continuada reportado pela APAV [2]. As correlações entre os itens-trigger e

os itens-alvo dos clusters são detetáveis pela análise de Pearson e por modelos baseados em árvores de decisão, confirmando que o sinal programado no gerador é recuperável pelo pipeline de análise.

4.3. Implementação do Pipeline de Pré-processamento

A implementação do pipeline de pré-processamento, contida no notebook `Excluir_ultimo_episodio.ipynb`, organiza-se em quatro etapas sequenciais: carregamento e construção da variável-alvo, codificação das respostas, construção de variáveis agregadas e divisão treino-teste por agressor. Todas as etapas são reprodutíveis a partir de uma seed fixa e a matriz final é compatível com qualquer estimador do scikit-learn.

4.3.1. Carregamento e construção da variável-alvo

A leitura é feita com `pandas.read_csv` sobre o ficheiro `dados/rvd11_portugal_v3.csv`, aplicando a configuração de ingestão descrita em 3.5.1. Os trinta mil registos são lidos numa única operação para o volume atual, ficando a interface compatível com leitura por lotes (parâmetro `chunksize`) caso o volume cresça.

Após a leitura, é construída a variável-alvo de modelação. Para cada agressor identificado pelo seu `ID_Agressor`, são contados os NUIPC distintos no conjunto: agressores com mais do que um NUIPC são marcados como reincidentes. Os episódios são ordenados cronologicamente e são atribuídos os atributos `EPISODIO_N` (ordem do episódio para o agressor) e `IS_LAST` (indicador de último episódio). O passo crítico consiste em remover do conjunto de modelação o último episódio de cada agressor reincidente, uma vez que esse episódio é exatamente o ponto em que ainda se ignora se haverá nova reincidência. A variável-alvo `TARGET` passa a indicar, para cada avaliação preservada, se existirá pelo menos mais um episódio registado a seguir.

4.3.2. Codificação das respostas

Cada item das secções A, B e C da ficha é traduzido em três indicadores binários distintos. O indicador `_bin` regista a resposta substantiva ($S \rightarrow 1$, $N \rightarrow 0$). O indicador `_SI` assinala as respostas Sem Informação. O indicador `_NA` assinala as respostas Não Aplicável.

A vantagem desta tripla codificação é metodológica. Se convertêssemos S/N/NA/SI numa única coluna numérica, perderíamos a diferença entre uma resposta genuinamente negativa (o agressor não exhibe esse comportamento) e uma resposta de ausência de informação (o agente não conseguiu apurar). Esta distinção é relevante: a ausência de informação pode, por si só, ser um sinal de risco e o modelo deve poder aprendê-la separadamente da resposta negativa.

As trinta questões da ficha — quinze das secções A e B, mais quinze de C distribuídas pelas três tipologias — produzem noventa colunas codificadas. A estas juntam-se sessenta sub-preditores numéricos provenientes diretamente do ficheiro gerado, depois de filtrados os campos de identificação que não devem entrar na modelação.

4.3.3. Variáveis agregadas e matriz final

Sobre os indicadores binários e os sub-preditores construímos dez variáveis adicionais com significado clínico ou estrutural.

O risco técnico atribuído pelo gerador é codificado em forma ordinal (RISCO_ORD) com os níveis baixo, médio, elevado e extremo. A tipologia é representada por três variáveis indicadoras (TIP_C1, TIP_C2, TIP_C3), com OUTRA como categoria de referência. Uma razão (RATIO_SIM) mede o quociente entre respostas afirmativas observadas e o total de respostas substantivas, normalizando pelo nível de informação disponível.

Quatro índices compostos sintetizam blocos temáticos da ficha:

- **IDX_SEVERIDADE** — soma de B2 (estrangulamento), B4 (uso de arma), B5 (ameaça de morte) e B6 (violência sexual).
- **IDX_CONTROLO** — soma de B3 (frequência ou gravidade), B7 (controlo coercivo), B8 (dependência) e B9 (isolamento).
- **IDX_VULNERABILIDADE** — soma de A5 (impulsividade) e A6 (risco suicidário).
- **IDX_AGRESSOR** — soma de A2 (antecedentes), A3 (substâncias) e A4 (instabilidade financeira).

O número do episódio, embora informativo, foi deliberadamente removido da matriz final por ser fonte direta de fuga de informação para a variável-alvo. A matriz final reúne a codificação binária dos itens, os sub-preditores numéricos e as variáveis agregadas, totalizando cerca de 150 variáveis explicativas — o número exato depende da configuração do ficheiro gerado.

4.4. Implementação dos Modelos

4.4.1. Divisão treino-teste por agressor

A divisão treino-teste é realizada ao nível do agressor, com 80% para treino e 20% para teste. Esta opção difere da divisão estratificada convencional por garantir que a totalidade dos episódios de um mesmo agressor fica num só conjunto, evitando que o modelo aprenda em treino e seja avaliado em teste sobre os mesmos indivíduos. A estratificação é aplicada sobre o valor máximo da variável-alvo por agressor, preservando a proporção de agressores com pelo menos uma reincidência em ambos os conjuntos.

4.4.2. Ajuste de hiperparâmetros com Optuna

A ajuste de hiperparâmetros é conduzida com Optuna [18], que implementa otimização Bayesiana com o sampler Tree-structured Parzen Estimator. Para cada um dos três modelos, é definido um espaço de procura sobre os hiperparâmetros relevantes e são executadas cinquenta tentativas. A avaliação interna utiliza GroupKFold com cinco folds, agrupando por ID_Agressor, para evitar a fuga de informação durante a validação cruzada. Para a Decision Tree, o espaço inclui max_depth, min_samples_leaf, min_samples_split, max_features e criterion. Para a Random Forest, acrescenta-se n_estimators e max_samples. Para o XGBoost, o espaço cobre n_estimators, max_depth, learning_rate, subsample, colsample_bytree, gamma, min_child_weight e os termos de regularização L1 e L2. Em todos os modelos, o desequilíbrio entre classes é tratado por ponderação: class_weight='balanced' para os classificadores baseados em árvores do scikit-learn e scale_pos_weight calculado a partir da razão entre classes para o XGBoost. Os hiperparâmetros ótimos identificados pela ajuste Bayesiana para o XGBoost — incluindo n_estimators=350, max_depth=5, learning_rate=0,059 e regularização L1/L2 — estão reportados na tabela em baixo.

Tabela 16: Hiperparâmetros ótimos do XGBoost identificados pela otimização Bayesiana com Optuna após cinquenta tentativas.

Hiperparâmetro	Valor óptimo
n_estimators	350
max_depth	5
learning_rate	0,0586
subsample	0,8187
colsample_bytree	0,6739
gamma	4,8479
min_child_weight	8
reg_alpha	4,6975
reg_lambda	4,4741




Figura 2: Trajetória da otimização Bayesiana com Optuna para os três classificadores: AUC obtido em validação cruzada (GroupKFold, $k=5$) ao longo das tentativas, em painéis paralelos.

4.4.3. Treino final, avaliação e interpretabilidade

Depois de a afinação ter selecionado os melhores hiperparâmetros, cada modelo é treinado uma única vez, agora sobre a totalidade do conjunto de treino — não apenas sobre os folds de validação cruzada. Cada modelo final é depois avaliado uma única vez no conjunto de teste, que ficou reservado desde a divisão inicial e nunca foi visto pelo processo de afinação. Esta sequência garante que as métricas reportadas correspondem ao desempenho esperado em dados verdadeiramente novos.

Os três classificadores produzem probabilidades posteriores para cada amostra. Estas probabilidades alimentam diretamente as métricas baseadas em ranking (AUC-ROC e AUC-PR). Para calcular métricas de classificação dura (sensibilidade, precisão e F1) é necessário converter cada probabilidade em decisão sim/não, o que se faz comparando-a com um limiar — no caso de base, 0,5; em produção, ajustado em função do tradeoff precisão-sensibilidade específico do contexto.

Sobre o Random Forest, que é o modelo retido para a camada de serviço operacional, calculam-se ainda valores SHAP por amostra com TreeSHAP [19], [20]. Estes valores suportam quatro tipos de análise: global (importância média absoluta por variável), distribucional (gráfico de enxame), local (explicação individual de uma previsão concreta) e de dependência (efeito de uma variável específica ao longo do seu domínio).

4.4.4. Função operacional de previsão com explicação

A camada de interpretabilidade é encapsulada numa função operacional, `prever_com_explicacao`, que aceita o índice de uma avaliação no conjunto de teste e produz quatro saídas integradas: a probabilidade estimada de reincidência, a classificação no nível de risco correspondente (Residual, Moderado ou Elevado, conforme a escala definida no Capítulo 3), a tabela das variáveis com maior contribuição SHAP para aquela previsão concreta (com magnitude, direção do efeito e barra visual) e o gráfico de cascata que decompõe a previsão a partir do valor base do modelo. Para tornar a saída legível por não especialistas, cada variável é apresentada com a respetiva descrição clínica em Português, obtida de um dicionário que mapeia os identificadores técnicos (A1_bin, B7_bin, etc.) às formulações operacionais usadas pelos órgãos de polícia criminal. Por exemplo, o item A1 é apresentado como "histórico de agressões anteriores ou ameaças graves". A versão integral deste dicionário figura no Anexo B.

Para demonstrar a possibilidade de disponibilização externa da lógica de previsão, foi desenvolvido um protótipo mínimo de serviço HTTP, implementado com FastAPI. Este serviço expõe o endpoint `POST /prever`, que recebe uma avaliação RVD-R estruturada, aplica as mesmas etapas de validação e pré-processamento utilizadas no pipeline experimental e devolve uma resposta composta pela probabilidade estimada de reincidência, pelo nível de risco operacional e pelas principais contribuições SHAP associadas à previsão.

Este serviço deve ser entendido como uma prova técnica de integração e não como uma solução operacional pronta para utilização em contexto real. A sua função é demonstrar que o modelo treinado pode ser encapsulado numa camada de inferência reutilizável por aplicações futuras, mantendo a rastreabilidade entre entrada, transformação dos dados, previsão e explicação. Por esse motivo, aspetos como gestão institucional de utilizadores, integração com bases de dados reais, auditoria completa de acessos, interface final de apoio à decisão e validação em ambiente produtivo não fazem parte do âmbito desta entrega.

A estrutura do pedido JSON enviado pela interface (front end) ao endpoint é apresentada na tabela seguinte; a estrutura da resposta devolvida pelo serviço é apresentada na tabela imediatamente a seguir.

Tabela 17: Estrutura do pedido JSON enviado pela interface (front end) ao endpoint POST /prever: campos, tipos, obrigatoriedade e descrição.

Campo	Tipo	Obrigatório	Descrição
TIPOLOGIA	C1 C2 C3 OUTRA	Sim	Tipologia de violência da avaliação
A1 a A6	S N N/A S/I	Sim	Itens da secção A — fatores de risco associados ao agressor
B1 a B9	S N N/A S/I	Sim	Itens da secção B — vulnerabilidade da vítima e histórico de violência
C1.1 a C3.5	S N N/A S/I	Não (predefinido N/A)	Itens da secção C, específicos da tipologia
Sub-indicadores (ex.: A1_VD)	0 1	Não	Detalham um item afirmativo (ex.: homicídio tentado ou consumado)
NUIPC; ID_Agressor; ID_Vitima; Data_Avaliacao	Texto	Não	Metadados de identificação; não entram nas variáveis do modelo

Tabela 18: Estrutura da resposta JSON devolvida pelo endpoint POST /prever: previsão, nível de risco, recomendação e explicação SHAP.

Campo	Tipo	Descrição
probabilidade	decimal [0 a 1]	Probabilidade estimada de reincidência
risco_classe	Residual Moderado Elevado	Nível de risco segundo os limiares operacionais
risco_descricao	Texto	Descrição clínica do risco com os principais fatores
recomendacao	Texto	Recomendação operacional associada ao nível de risco
modelo	Texto	Nome do modelo que produziu a previsão
shap.base_value	decimal	Valor base do modelo
shap.prediction_value	decimal	Valor base somado às contribuições SHAP
shap.contribuicoes[]	lista	Por variável: nome, descrição clínica, valor de entrada, valor SHAP e direção

4.5. Desafios Técnicos

Três desafios estruturaram o desenho atual. O primeiro foi a preservação semântica das respostas N/A e S/I durante a leitura: a configuração predefinida do pandas convertia-as silenciosamente em valores ausentes, problema resolvido com `keep_default_na=False` e com a codificação tripla por questão. O segundo foi a definição de uma variável-alvo que não inflacionasse trivialmente as métricas: a alternativa adotada, de remover apenas o último episódio dos agressores reincidentes e responder à pergunta sobre o aparecimento de pelo menos mais um episódio, exige que a leitura das métricas seja feita tendo em conta a presença de muitos episódios estruturalmente positivos. O terceiro foi a fuga de informação entre treino e teste quando episódios do mesmo agressor são distribuídos pelos dois conjuntos, resolvida pela divisão por grupo (`GroupKFold` na validação cruzada e divisão por agressor na separação treino-teste).

A experiência destes três desafios mostrou a importância de tornar explícitas, no Capítulo 6, as condições em que cada métrica deve ser lida.

4.6. Alternativas Consideradas

Várias decisões técnicas tomadas ao longo do projeto resultaram da comparação explícita entre alternativas. As mais relevantes são documentadas a seguir, com a justificação da escolha final, para permitir replicação crítica do trabalho.

No plano dos dados, a alternativa principal era a aquisição de registos reais junto da Direção-Geral da Política de Justiça ou da Polícia de Segurança Pública. A natureza dos dados (categorias especiais ao abrigo do Art. 9 do RGPD), o tempo necessário para obter parecer da Comissão Nacional de Proteção de Dados e o horizonte temporal desta entrega tornaram inviável esta via. A geração assistida por LLM, calibrada contra estatísticas oficiais agregadas (RASI, APAV, PAVD), permite produzir um conjunto estruturalmente válido para testar o pipeline, sabendo que a transferibilidade para dados reais fica reservada a fases posteriores.

No plano dos modelos, foram consideradas três famílias além das três retidas. A regressão logística foi descartada por não captar interações não-lineares entre variáveis sem engenharia manual de termos. As redes neuronais profundas foram excluídas pela dimensão do conjunto (~30 000 registos) e pela perda de interpretabilidade que implicariam, em contradição com o argumento de Rudin [47] sobre decisões de alto risco. O LightGBM foi considerado como alternativa ao XGBoost mas dispensado por convergência de desempenho conhecida para conjuntos desta dimensão e por menor maturidade do suporte TreeSHAP no momento do trabalho.

No plano da estratégia de validação, a alternativa simples de `train_test_split` aleatório foi rejeitada por permitir fuga de informação quando o mesmo agressor tem múltiplos episódios. Considerou-se ainda validação cruzada estratificada simples (`StratifiedKFold`), também ela vulnerável à contaminação inter-fold. A solução `GroupKFold(k=5)` agrupada por identificador de agressor é a única que garante a separação entre indivíduos.

No plano da camada de serviço, foram avaliados Flask e Django REST Framework antes da escolha do FastAPI. O Flask foi descartado por ausência nativa de validação por schema e de documentação automática OpenAPI; o Django REST Framework por sobrepeso arquitetural face à dimensão do problema (não há domínio relacional nem autenticação a gerir nesta entrega). O FastAPI combina validação Pydantic — alinhada com a tipagem nativa Python — e OpenAPI automático com latência mínima, o que serve a função exploratória do serviço sem comprometer o futuro produtivo.

5. Testes e Validação

5.1. Estratégia de Testes

A validação da solução decorreu em duas frentes complementares. A primeira é a verificação do software que suporta o pipeline e a camada de serviço, organizada em três níveis — testes unitários, de integração e de sistema — automatizados com a framework pytest. A segunda é a avaliação experimental dos modelos sobre o conjunto de teste reservado, que mede o desempenho preditivo e a sua estabilidade.

Esta secção descreve primeiro os testes de software, com exemplos concretos e os resultados obtidos, e depois a avaliação experimental dos modelos. A suite automatizada conta com 40 testes distribuídos pelos três níveis e é re-executável com um único comando (pytest). Os valores de input e output indicados nos exemplos correspondem ao comportamento efetivo da aplicação.

5.2. Testes de Software

5.2.1. Testes unitários

Os testes unitários validam funções e métodos de forma isolada, sem dependências externas. O seu objetivo é garantir que cada transformação elementar dos dados produz exatamente a saída esperada antes de ser integrada no pipeline. Cobrem o núcleo do pré-processamento e da validação clínica: a codificação tripla de cada resposta, o tratamento das categorias N/A e S/I como sinal, a coerência entre um item principal e os seus sub-indicadores, a remoção do último episódio dos agressores reincidentes e as regras de aceitação de identificadores e datas.

5.2.2. Testes de integração

Os testes de integração confirmam que os diferentes módulos comunicam corretamente entre si. Verificam o percurso completo de um pedido na camada de serviço — validação, codificação, inferência e cálculo das contribuições SHAP — e propriedades que atravessam vários componentes, como a aditividade do SHAP (o valor base somado às contribuições reproduz a probabilidade) e a correspondência entre a probabilidade e o nível de risco devolvido. Confirmam ainda que o número de contribuições devolvidas corresponde ao número de variáveis do modelo.

5.2.3. Testes de sistema

Os testes de sistema avaliam o comportamento global da aplicação do ponto de vista de quem a consome. Levantam o serviço em memória e exercitam os endpoints públicos: a verificação de saúde (/saude), o fluxo de previsão (POST /prever) com avaliações completas e mínimas, a

documentação automática (OpenAPI) e o controlo de acesso por token. Incluem casos extremos — avaliação totalmente negativa, totalmente afirmativa, ou com respostas inteiramente N/A ou S/I — e a verificação de que o mesmo pedido devolve sempre a mesma probabilidade (determinismo).

5.3. Casos de Teste

A tabela seguinte resume casos de teste representativos, com o input fornecido e o output esperado. Selecionaram-se os casos que cobrem as transformações mais críticas do pipeline e as regras de coerência clínica da camada de serviço.

Tabela 19: Casos de teste representativos por nível (unitário, integração e sistema), com o input fornecido e o output esperado.

Caso de teste	Nível	Input	Output esperado
Leitura do ficheiro CSV	Unitário	RVD-R com respostas S; N; N/A e S/I	Quatro categorias preservadas (sem conversão para valor ausente)
Preservação de N/A e S/I	Unitário	Item com N/A e outro com S/I	Codificação distingue N/A e S/I de N; ambas tratadas como sinal
Codificação tripla	Unitário	Resposta S num item	Três indicadores gerados (afirmativa; N/A; S/I) com afirmativa = 1
Validação de identificadores	Unitário	NUIPC com formato inválido	Pedido rejeitado com HTTP 422
Coerência clínica	Unitário	Homicídio assinalado sem A1 = S	Pedido rejeitado com HTTP 422
Cálculo de variáveis agregadas	Unitário	Avaliação com vários itens afirmativos	Índices compostos calculados com o valor esperado
Remoção do último episódio	Unitário	Agressor reincidente com N episódios	Último episódio excluído; N-1 episódios retidos

Fluxo de previsão	Integração	Avaliação completa C1	Resposta 200 com probabilidade; classe e contribuições SHAP
Aditividade do SHAP	Integração	Avaliação completa	Valor base somado às contribuições aproxima a probabilidade
Autenticação	Sistema	Pedido sem token (autenticação ativa)	Resposta HTTP 401
Determinismo	Sistema	Mesmo pedido repetido	Mesma probabilidade nas duas chamadas

5.4. Avaliação Experimental dos Modelos

Para além da verificação do software, a solução é validada pela avaliação experimental dos modelos sobre o conjunto de teste, isolado por divisão por agressor (20%) e nunca observado durante o treino ou a afinação. Esta avaliação cobre quatro dimensões complementares.

A primeira é o desempenho global dos três modelos. A segunda é a estabilidade entre validação cruzada e teste — compara-se o AUC-ROC médio obtido por GroupKFold no treino com o AUC-ROC efetivo no teste, como medida de generalização. A terceira é a análise por episódio: o desempenho no primeiro episódio (predição genuína, sem informação trivialmente positiva) é separado do desempenho nos episódios seguintes. A quarta é a interpretabilidade — a estabilidade das estimativas de importância ao longo dos folds e a concordância entre a importância intrínseca dos modelos de árvores e os rankings TreeSHAP.

O caso de avaliação principal aplica os três classificadores afinados ao conjunto de teste completo. O caso complementar do primeiro episódio aplica os mesmos modelos apenas às avaliações de ordem um, isolando o subgrupo em que a previsão tem valor preditivo real. Complementa-se com a análise do desempenho por tipologia de violência (C1, C2, C3 e OUTRA) e por nível de risco técnico RVD-R.

5.5. Tratamento de Fuga de Informação entre Episódios

Uma das contribuições metodológicas do trabalho é o reconhecimento e o tratamento explícito de uma fuga de informação que afeta os modelos de previsão de reincidência treinados sobre dados longitudinais como os da ficha RVD-R. Na configuração ingénua, em que todas as avaliações de um agressor entram em treino, os episódios de ordem superior são, por construção, sempre positivos para uma variável-alvo definida como "existe pelo menos mais um episódio a seguir".

Esta particularidade inflaciona artificialmente o desempenho aparente, porque o modelo aprende a identificar avaliações que já estão dentro de uma sequência de reincidência, e não a prever se uma primeira avaliação irá ou não evoluir para reincidência. Em desenvolvimentos preliminares conduzidos no notebook `modelo_todas_avaliacoes.ipynb`, esta configuração produziu valores de AUC-ROC sistematicamente elevados que não se mantinham quando o modelo era avaliado apenas nas primeiras avaliações de cada agressor.

A solução adotada — remover do conjunto de modelação o último episódio de cada agressor reincidente — preserva todos os episódios anteriores e mantém o sinal genuíno, sem nunca expor o modelo a um exemplo trivialmente positivo. Esta opção permite que a métrica global e a métrica restrita ao primeiro episódio sejam ambas interpretáveis e comparáveis. A demonstração quantitativa do efeito da fuga de informação, com os valores de AUC nas duas configurações lado a lado, é apresentada no Capítulo 6 e suporta a justificação metodológica desta escolha.

5.6. Resultados dos Testes

Os testes de software executam sem falhas: as 40 verificações automatizadas passam na totalidade. A tabela seguinte resume o resultado por nível de teste.

Tabela 20: Resultado da execução dos testes de software por nível: número de testes e estado (todos passam).

Nível	Área coberta	N.º de testes	Resultado
Unitário	Codificação tripla das respostas e validação de coerência clínica	19	Todos passam
Integração	Pipeline de inferência e aditividade do SHAP	12	Todos passam
Sistema	Arranque do serviço; endpoints; autenticação	9	Todos passam
Total		40	Todos passam

Este resultado confirma, em concreto, que o pré-processamento preserva a semântica das respostas (incluindo N/A e S/I), que as regras de coerência clínica rejeitam os pedidos malformados com o código de erro esperado, que a explicação SHAP é aritmeticamente coerente com a probabilidade prevista e que o controlo de acesso por token funciona como especificado.

A avaliação experimental dos modelos confirma a existência de sinal preditivo. Sobre o conjunto de teste, os três classificadores obtêm valores de AUC-ROC próximos — 0,645 para a árvore de decisão, 0,710 para o Random Forest e 0,715 para o XGBoost — mas separam-se claramente na

sensibilidade: o Random Forest deteta 60,7% dos reincidentes, contra apenas 22,0% do XGBoost afinado. Por esse motivo, e pelo custo elevado dos falsos negativos neste domínio, o Random Forest é o modelo retido para a camada operacional.

A demonstração da fuga de informação confirma a necessidade do tratamento adotado: o mesmo Random Forest atinge um AUC-ROC de 0,760 quando todas as avaliações entram no treino, contra 0,710 na configuração correta — uma diferença que corresponde a desempenho aparente, e não a capacidade preditiva real.

As tabelas e figuras completas — métricas por modelo, matrizes de confusão, curvas ROC e precisão-sensibilidade, desempenho por tipologia e análise de falsos negativos — são apresentadas e discutidas em detalhe no Capítulo 6.

5.7. Validação dos Requisitos

A validação confirma o cumprimento dos requisitos definidos no Capítulo 3. Os requisitos funcionais RF-01 a RF-08 — ingestão, construção da variável-alvo sem fuga, pré-processamento reprodutível, divisão por agressor, treino comparativo, afinação automática, avaliação por métricas adequadas e interpretabilidade — estão implementados e verificados pelos testes e pelas tabelas do Capítulo 6. O requisito RF-09 (serviço de inferência com validação clínica) está operacional e coberto pelos testes de integração e de sistema.

Quanto aos requisitos não-funcionais, estão cumpridos a reprodutibilidade (RNF-01), a interpretabilidade operacional (RNF-02), a equidade entre subgrupos (RNF-04, com variação de AUC de 0,026), a portabilidade e custo zero (RNF-05) e a segurança da camada de serviço (RNF-06). A conformidade regulamentar (RNF-03) é tratada nos Capítulos 3.6 e 7.5.

6. Resultados e Discussão

6.1. Apresentação de Resultados

O conjunto de modelação contém 22 500 agressores únicos avaliados entre janeiro de 2023 e dezembro de 2025, dos quais 6 662 (29,6%) são classificados como reincidentes pela definição adotada — pelo menos dois NUIPC distintos associados ao mesmo agressor. A divisão treino/teste foi feita ao nível do agressor, com 18 000 agressores em treino e 4 500 em teste, preservando a proporção de reincidentes em ambos os conjuntos (29,5% e 30,0% respetivamente).

Tabela 21: Caracterização do conjunto de dados sintéticos utilizado: total de avaliações, agressores e vítimas únicos, período coberto, agressores reincidentes e tipologias representadas.

Métrica	Valor
Total de avaliações	30 425
Agressores únicos	22 500
Vítimas únicas	22 500
Período (primeiro registo)	2023-01-01
Período (último registo)	2025-12-31
Agressores reincidentes	6 662
Taxa de reincidência	29,6%
Tipologias representadas	C1, C2, C3, OUTRA

Tabela 22: Divisão do conjunto em treino e teste por agressor, com a proporção de reincidentes em cada subconjunto.

Conjunto	N agressores	% Reincidentes
Treino	18000	29,5%
Teste	4500	30,0%
Total	22500	29,6%




Figura 3: Distribuição da variável-alvo no conjunto de modelação (primeira avaliação por agressor): número e proporção de agressores reincidentes e não reincidentes.

A distribuição dos agressores pelos cinco níveis de risco técnico atribuídos pela ficha RVD-R revela uma assimetria esperada: 8 472 agressores em risco BAIXO, 5 583 em risco MÉDIO, 2 985 em risco ELEVADO e 4 019 em risco EXTREMO (ver figura em baixo). A taxa observada de reincidência cresce monotonicamente com o nível de risco, de 16,4% no nível BAIXO até 51,2% no EXTREMO, confirmando que a classificação RVD-R captura ordinalmente o risco, embora com desempenho discriminativo limitado quando usada isoladamente.




Figura 4: Distribuição dos agressores pelos cinco níveis de risco técnico atribuídos pela ficha RVD-R, no conjunto de modelação.

Tabela 23: Taxa observada de reincidência por nível de risco RVD-R no conjunto de modelação.

Nível de risco	N agressores	Reincidentes	Taxa de reincidência
BAIXO	8 472	1 392	16,4%
MÉDIO	5 583	1 624	29,1%
MÉDIO (Insuficiente)	1 441	270	18,7%
ELEVADO	2 985	1 319	44,2%
EXTREMO	4 019	2 057	51,2%




Figura 5: Taxa observada de reincidência por nível de risco RVD-R; a linha tracejada indica a média global.

A tabela em baixo sintetiza as métricas dos três classificadores no conjunto de teste. O Random Forest atinge AUC-ROC de 0,710 e F1 de 0,531, com sensibilidade de 0,607. O XGBoost afinado com Optuna obtém o AUC-ROC mais elevado (0,715), mas com uma configuração de hiperparâmetros que privilegia a precisão (0,571) em detrimento da sensibilidade (0,220), produzindo F1 de apenas 0,318. A Decision Tree estabelece a linha de base com AUC-ROC de 0,645 e F1 de 0,483. As matrizes de confusão dos três modelos no conjunto de teste e as respetivas curvas ROC e precisão-sensibilidade estão apresentadas em baixo.

Tabela 24: Métricas dos três classificadores no conjunto de teste: accuracy, precisão, sensibilidade, F1 e AUC.

Modelo	Accuracy	Precision	Recall	F1-score	AUC
Árvore de Decisão	0,609	0,400	0,608	0,483	0,645
Random Forest	0,679	0,473	0,607	0,531	0,710
XGBoost (Optuna)	0,717	0,571	0,220	0,318	0,715

Tabela 25: Relatório de classificação detalhado por classe e por modelo no conjunto de teste.

Modelo	Classe	Precision	Recall	F1-score	Support
Árvore de Decisão	Não reincidente	0,784	0,610	0,686	3152
Árvore de Decisão	Reincidente	0,400	0,608	0,483	1348
Random Forest	Não reincidente	0,809	0,710	0,756	3152
Random Forest	Reincidente	0,473	0,607	0,531	1348
XGBoost (Optuna)	Não reincidente	0,736	0,929	0,821	3152
XGBoost (Optuna)	Reincidente	0,571	0,220	0,318	1348

Matrizes de confusão por modelo




Figura 6: Matrizes de confusão para os três classificadores no conjunto de teste, em contagens absolutas.




Figura 7: Curvas ROC para os três classificadores no conjunto de teste, com AUC respetivo.




Figura 8: Curvas precisão-sensibilidade para os três classificadores no conjunto de teste, com AUC-PR respetivo.

A análise por validação cruzada (GroupKFold, $k=5$) confirma a estabilidade das métricas reportadas no conjunto de teste. O AUC-ROC médio é de $0,641 \pm 0,009$ para a Decision Tree, $0,696 \pm 0,009$ para o Random Forest e $0,699 \pm 0,009$ para o XGBoost, com intervalos sobrepostos entre os dois modelos de ensemble.

Tabela 26: Métricas obtidas por validação cruzada (GroupKFold, k=5) no conjunto de treino, reportadas como média $\pm$ desvio padrão.

Modelo	Accuracy	Precision	Recall	F1-score	AUC
Árvore de Decisão	0,615 $\pm$ 0,006	0,398 $\pm$ 0,007	0,594 $\pm$ 0,011	0,477 $\pm$ 0,008	0,641 $\pm$ 0,009
Random Forest	0,672 $\pm$ 0,007	0,457 $\pm$ 0,009	0,591 $\pm$ 0,012	0,515 $\pm$ 0,010	0,696 $\pm$ 0,009
XGBoost (Optuna)	0,716 $\pm$ 0,003	0,544 $\pm$ 0,012	0,240 $\pm$ 0,018	0,333 $\pm$ 0,017	0,699 $\pm$ 0,009




Figura 9: Distribuição do AUC obtido em validação cruzada (GroupKFold, k=5) por modelo, em diagrama de caixa.

A análise de threshold para o modelo retido mostra como as métricas variam em função do limiar de decisão. No limiar operacional de 0,33 (corte entre risco residual e moderado), a precisão é de 0,474 e a sensibilidade de 0,618, com 515 falsos negativos. O comportamento por tipologia de violência está apresentado em baixo: o Random Forest mantém AUC entre 0,701 (OUTRA) e 0,727 (C2), confirmando estabilidade entre subgrupos.

Tabela 27: Métricas em função do limiar de decisão para o modelo retido, com destaque para os limiares operacionais 0,33 e 0,66.

Threshold	Precision	Recall	F1-score	Especificidade	Falsos negativos
0,33	0,474	0,618	0,536	0,706	515
0,40	0,519	0,458	0,487	0,819	731
0,50	0,571	0,220	0,318	0,929	1051
0,66	0,000	0,000	0,000	1,000	1348
0,28	0,455	0,694	0,549	0,644	413

A análise dos limiares de decisão evidencia que a escolha do threshold tem impacto direto no equilíbrio entre precisão e sensibilidade. Como esperado, limiares mais baixos aumentam a capacidade do modelo para identificar casos reincidentes, embora à custa de uma maior proporção de falsos positivos. Pelo contrário, limiares mais elevados tornam o modelo mais conservador, reduzindo o número de casos classificados como reincidentes, mas aumentando o risco de falsos negativos.

No contexto específico deste trabalho, observa-se que o limiar de 0,33 apresenta maior utilidade exploratória do que o limiar de 0,66, uma vez que permite preservar uma sensibilidade mais compatível com o objetivo de deteção precoce. Já o limiar de 0,66 revela-se demasiado exigente para o modelo treinado sobre dados sintéticos, produzindo uma classificação excessivamente restritiva e reduzindo substancialmente a identificação de casos positivos. Este resultado sugere que a discretização em três níveis deve ser revista em fases futuras, com recurso a dados reais e a técnicas formais de calibração probabilística.

Assim, os resultados desta análise não devem ser interpretados como validação definitiva dos limiares operacionais, mas como uma demonstração da necessidade de ajustar os thresholds ao objetivo do sistema. Em particular, num domínio em que o custo dos falsos negativos é elevado, poderá ser mais adequado definir limiares orientados por uma sensibilidade mínima aceitável, por análise custo-benefício ou por validação pericial, em vez de recorrer a cortes fixos e simétricos.




Figura 10: Análise de threshold para o Random Forest (modelo retido para a camada operacional): precisão, sensibilidade e F1 em função do limiar de decisão.

Tabela 28: AUC por tipologia de violência (C1, C2, C3 e OUTRA) para cada um dos três classificadores.

Tipologia	Árvore de Decisão	Random Forest	XGBoost (Optuna)
C1	0,639	0,704	0,709
C2	0,672	0,727	0,735
C3	0,656	0,711	0,723
OUTRA	0,649	0,701	0,699




Figura 11: AUC por tipologia de violência (C1, C2, C3 e OUTRA) para cada um dos três classificadores.

6.2. Discussão Crítica

A leitura conjunta das métricas obtidas permite três observações centrais que orientam a escolha do modelo a integrar na camada operacional e a interpretação do desempenho global.

A primeira observação é que os três modelos superam o baseline da ficha RVD-R utilizada isoladamente como classificador binário (regra ELEVADO/EXTREMO → reincide), que atinge AUC de 0,678 e F1 de 0,500 (ver tabela e figura em baixo). O ganho do Random Forest sobre esta linha de base é mensurável tanto em AUC (+0,032) como em F1 (+0,031), confirmando que o ML acrescenta valor preditivo face à simples leitura ordinal do nível de risco. Este resultado é consistente com a meta-análise de Hanson, Helmus e Bourgon, que documenta capacidade preditiva apenas moderada dos instrumentos quando usados sozinhos [5], e com o estudo de Berk e Sorenson, que mostrou ganhos operacionais substanciais com modelos de Machine Learning em contexto judicial análogo [10].

Tabela 29: Comparação entre o baseline RVD-R (regra ELEVADO/EXTREMO → reincide) e os três modelos de Machine Learning.

Classificador	Accuracy	Precision	Recall	F1-score	AUC
Baseline RVD-R (ELEVADO/EXTREMO → Sim)	0,694	0,490	0,511	0,500	0,678
Árvore de Decisão	0,609	0,400	0,608	0,483	0,645
Random Forest	0,679	0,473	0,607	0,531	0,710
XGBoost (Optuna)	0,717	0,571	0,220	0,318	0,715




Figura 12: Comparação entre o baseline RVD-R (regra ELEVADO/EXTREMO → reincide) e os três modelos de Machine Learning.

A segunda observação confirma empiricamente o argumento multi-eixo apresentado no Capítulo 3 sobre a seleção do modelo a integrar no protótipo de inferência. O XGBoost afinado com Optuna obtém o AUC-ROC mais elevado (0,715), mas a configuração avaliada privilegia a precisão (0,571) em detrimento da sensibilidade (0,220), com um F1 de apenas 0,318. Em contraste, o Random Forest atinge um AUC praticamente equivalente (0,710, com intervalos de validação cruzada

sobrepostos), mas apresenta uma sensibilidade substancialmente superior (0,607) e um F1 mais equilibrado (0,531).

Esta diferença é particularmente relevante no domínio da violência doméstica, onde o custo social de um falso negativo é desproporcionadamente elevado. Um falso negativo corresponde a um caso potencialmente reincidente que o modelo não sinaliza como tal, podendo contribuir para uma perceção subestimada do risco. Por essa razão, a escolha do modelo não deve ser guiada apenas pela métrica AUC-ROC, mas por uma leitura multidimensional que considere a sensibilidade, a estabilidade, a interpretabilidade e a adequação ao objetivo de apoio à decisão humana.

Deste modo, a opção pelo Random Forest justifica-se por representar um compromisso mais equilibrado entre desempenho preditivo, capacidade de deteção de reincidentes e interpretabilidade. Esta decisão é coerente com o argumento de Rudin, segundo o qual a métrica preditiva isolada não deve orientar, por si só, a escolha de modelos em contextos de decisão de alto risco [47]. Ainda assim, esta escolha não deve ser entendida como definitiva para uma aplicação operacional real. Em trabalho futuro, será necessário reavaliar os modelos com dados reais, testar diferentes limiares de decisão para cada classificador e comparar os modelos sob condições equivalentes de sensibilidade mínima, de modo a confirmar se o Random Forest mantém a vantagem observada neste estudo exploratório.

Tabela 30 - Comparação de AUC do Random Forest entre o regime correto (primeira avaliação por agressor) e o regime com fuga de informação (todas as avaliações).

Regime de amostragem	N treino	N teste	AUC (Random Forest)
Primeira avaliação por agressor (correcto)	18 000	4 500	0,710
Todas as avaliações (com leakage)	24 320	6 105	0,760




Figura 13: Demonstração quantitativa do efeito de fuga de informação: AUC do Random Forest treinado apenas sobre primeiras avaliações (correcto) face ao treino sobre todas as avaliações (com fuga).

Em síntese, os três objetivos específicos definidos no Capítulo 1 que dependem desta análise estão cumpridos: existem três modelos treinados, avaliados e comparados com métricas adequadas a classes desequilibradas; existe um modelo selecionado para a camada operacional com base num critério explícito e fundamentado; e a validade interna dos resultados foi confirmada por validação cruzada agrupada por agressor, eliminando a principal fonte de fuga de informação.

6.3. Análise de Preditores e Interpretabilidade (XAI)

A análise de importância das variáveis recorre a duas dimensões complementares. A primeira utiliza a importância intrínseca devolvida pelos modelos baseados em árvores (atributo `feature_importances_`), que ordena as variáveis pela sua contribuição cumulativa para a redução da impureza durante o treino. A segunda utiliza valores de Shapley calculados pelo TreeSHAP sobre o modelo retido para a camada operacional [19], [20], que devolve atribuições exatas com sinal e magnitude por amostra, com leituras globais (importância média absoluta, distribuição em gráfico de enxame), locais (gráfico de cascata para casos concretos) e de dependência (efeito marginal e interações). A concordância entre estas duas dimensões é reportada como medida da consistência interpretativa do modelo e constitui um dos critérios da sua seleção.

A análise de correlação no conjunto de treino ordena as variáveis pela sua correlação de Pearson absoluta com a variável-alvo. O preditor mais informativo é a pontuação total das respostas afirmativas (TOTAL_PONTOS_S, correlação 0,308), seguido por A1 (antecedentes de violência, 0,256), A5 (impulsividade, 0,209), B2 (estrangulamento, 0,202) e B3 (aumento de frequência ou gravidade, 0,190). Estes cinco preditores correspondem aos fatores de risco priorizados pela literatura portuguesa: a violência prévia ocupa o primeiro lugar no estudo da Universidade do Porto sobre homicídio conjugal [8] e na grelha de Morais-Gonçalves e colaboradores [9]; a escalação e o estrangulamento são, em conjunto com o uso de arma e a ameaça de morte, os fatores de letalidade mais frequentes nos casos analisados pelo Ministério Público em 2023 [21].

Tabela 31: Vinte variáveis com correlação de Pearson mais elevada com a variável-alvo no conjunto de treino, em valor absoluto.

Feature	Correlação REINCIDENTE	com	Magnitude
TOTAL_PONTOS_S	0,308		0,308
A1_S	0,256		0,256
A5_S	0,209		0,209
B2_S	0,202		0,202
B3_S	0,190		0,190
A1_N	-0,185		0,185
B4_S	0,181		0,181
B7_S	0,163		0,163
B1_S	0,162		0,162
A3_S	0,143		0,143
B2_N	-0,136		0,136
A5_N	-0,134		0,134
B8_S	0,129		0,129
A6_S	0,128		0,128
C1.3_S	0,123		0,123
C1.2_S	0,122		0,122
B3_N	-0,119		0,119

B4_N	-0,117	0,117
C1.4_S	0,116	0,116
B5_S	0,116	0,116




Figura 14: Heatmap das vinte variáveis mais correlacionadas com a reincidência, no conjunto de treino.

A importância intrínseca devolvida pelos três modelos está apresentada em baixo, com os quinze preditores de topo por classificador. Os dois modelos de ensemble (Random Forest e XGBoost) atribuem peso semelhante às variáveis A1, A5, B2 e B3, mas diferem no tratamento das variáveis agregadas (IDX_SEVERIDADE, IDX_CONTROLO, TOTAL_PONTOS_S): o Random Forest tende a distribuir importância pelo conjunto de itens individuais, enquanto o XGBoost concentra peso nos índices compostos. A concordância ordinal entre a importância intrínseca do Random Forest e a

correlação de Pearson é elevada, com sobreposição da maioria das dez primeiras variáveis em ambas as ordenações — propriedade que reforça a credibilidade interpretativa do modelo selecionado.




Figura 15: Top 15 variáveis por importância intrínseca (impurity-based Gini) calculadas pelo Random Forest no conjunto de treino.

A análise dos falsos negativos do modelo retido permite identificar onde está concentrado o erro residual. A esmagadora maioria dos falsos negativos provém dos níveis de risco BAIXO e MÉDIO, em que o modelo classifica corretamente a maioria como não reincidente mas falha em alguns casos genuínos. Nos níveis ELEVADO e EXTREMO, o modelo retém apenas 2,4% e 2,5% de falsos negativos respetivamente, o que é operacionalmente desejável: os casos com indicadores claros de risco são sinalizados com grande fiabilidade. A fração global de falsos negativos é de 39,3%, concentrada quase totalmente em agressores que a ficha RVD-R já classifica como BAIXO ou MÉDIO — situações em que tanto o instrumento clínico como o modelo de ML concordam em desvalorizar o risco aparente.

Tabela 32: Falsos negativos do modelo retido agregados por nível de risco técnico RVD-R, no conjunto de teste.

Nível de risco	Falsos negativos	Verdadeiros positivos	% perdidos pelo modelo
BAIXO	270	1	99,6%
MÉDIO	200	140	58,8%
MÉDIO (Insuficiente)	43	5	89,6%
ELEVADO	7	281	2,4%
EXTREMO	10	391	2,5%
TOTAL	530	818	39,3%

Análise de falsos negativos: quem o modelo não detecta




Figura 16: Análise dos falsos negativos do modelo selecionado, agregados por nível de risco técnico.

A análise de valores SHAP confirma e enriquece a leitura feita anteriormente. A importância média absoluta dos valores SHAP (Figura SHAP em baixo) coloca no topo a pontuação total das respostas afirmativas (TOTAL_PONTOS_S), seguida pela proporção dessas respostas (RATIO_SIM), pelo item A1 e pela sub-flag A1_VD (violência doméstica reportada como antecedente). A figura beeswarm em baixo completa a leitura mostrando direção e magnitude: valores elevados destas variáveis empurram sistematicamente a previsão para a classe Reincide, com baixa dispersão e ausência de efeitos não-monotónicos relevantes — propriedade que reforça a credibilidade interpretativa do modelo selecionado.




Figura 17: Importância SHAP média absoluta por variável, calculada sobre o Random Forest no conjunto de teste (top 15).




Figura 18: Distribuição dos valores SHAP por amostra e por variável (top 15) para o Random Forest. A cor representa o valor da variável; o eixo horizontal a contribuição para a previsão da classe Reincide.

Para tornar concreta a leitura individual da previsão, foram selecionados três casos paradigmáticos no conjunto de teste, um por nível de risco. O caso de risco residual (probabilidade próxima de 0,19) ilustra como a ausência de indicadores afirmativos empurra a previsão para baixo do valor base; o caso de risco moderado (probabilidade próxima de 0,50) mostra um equilíbrio entre contribuições positivas e negativas; e o caso de risco elevado (probabilidade próxima de 0,83) revela várias contribuições positivas de grande magnitude que justificam o sinal de alarme. Estes três gráficos de cascata, produzidos pela função `prever_com_explicacao` descrita no Capítulo 4, constituem a base da interface clínica que a API devolve a cada pedido.




Figura 19: Explicação SHAP de uma previsão classificada como de risco residual (probabilidade inferior a 33%), com decomposição a partir do valor base do modelo.




Figura 20: Explicação SHAP de uma previsão classificada como de risco moderado (probabilidade entre 33% e 66%).




Figura 21: Explicação SHAP de uma previsão classificada como de risco grave (probabilidade superior a 66%).

Finalmente, os gráficos de dependência para as quatro variáveis de maior impacto médio mostram efeitos predominantemente lineares no intervalo observado, com interações automáticas detetadas pelo SHAP que correspondem, na maioria dos casos, a outros indicadores clinicamente coerentes (por exemplo, A1 interage com A1_VD e com RATIO_SIM). A ausência de interações fortes e inesperadas é operacionalmente desejável: sugere que o comportamento do modelo é explicável a partir de relações marginais entre variáveis, sem depender de combinações exóticas difíceis de auditar.




Figura 22: Gráficos de dependência SHAP para as quatro variáveis de maior impacto médio sobre o Random Forest, com coloração pela variável de interação detetada automaticamente em cada painel.

6.4. Limitações dos Resultados

A principal limitação dos resultados decorre da natureza sintética do conjunto de dados. O treino e a avaliação dos modelos são realizados sobre registos gerados a partir de estatísticas agregadas e da literatura empírica disponível, sem confronto com dados reais. Em consequência, as métricas reportadas são interpretáveis como uma demonstração metodológica do pipeline completo — geração, pré-processamento, modelação, interpretabilidade — e não como medidas finais do desempenho que o sistema teria em contexto operacional.

A transferibilidade dos modelos para o contexto operacional exige validação posterior com dados anonimizados das forças de segurança, em fases posteriores do projeto.

7. Conclusão e Trabalho Futuro

7.1. Sumário e Contributos

O presente trabalho desenvolveu, sobre dados sintéticos da ficha RVD-R calibrados a partir de fontes oficiais portuguesas, um pipeline reproduzível de classificação binária para a previsão de reincidência em violência doméstica. O pipeline cobre as etapas de geração dos dados, ingestão por lotes, limpeza e codificação, construção de variáveis agregadas, treino comparativo de três famílias de modelos e avaliação por métricas adequadas a classes desequilibradas, com análise quer global quer por tipologia de violência. O contributo principal reside na metodologia, em particular na arquitetura de geração assistida por LLM ancorada em estatísticas oficiais (RASI, CIG, APAV) e na literatura empírica portuguesa, e no desenho de um pipeline auditável, computacionalmente leve e prontamente integrável com dados reais quando estes estiverem disponíveis em fases posteriores do projeto.

7.2. Objetivos Alcançados

Os seis objetivos específicos enunciados no Capítulo 1 foram cumpridos:

O primeiro objetivo — caracterizar o conjunto de dados sintéticos da RVD-R — foi cumprido. O conjunto reúne 30 425 avaliações de 22 500 agressores únicos, com uma taxa global de reincidência de 29,6%, enquadrada entre as referências empíricas portuguesas (22,7% no PAVD, 53,4% na vitimação continuada APAV).

O segundo objetivo — construir um pipeline reproduzível de ingestão e pré-processamento — está implementado em `Excluir_ultimo_episodio.ipynb` e em `preprocess.py`, com codificação tripla por questão, variáveis agregadas com significado clínico e divisão treino/teste por agressor para evitar fuga de informação.

O terceiro objetivo — treinar e comparar três famílias de modelos — foi cumprido com Decision Tree, Random Forest e XGBoost, todos afinados com Optuna por validação cruzada GroupKFold (k=5).

O quarto objetivo — avaliação por métricas adequadas a classes desequilibradas — foi cumprido. O Random Forest atinge AUC-ROC 0,710, F1 0,531 e sensibilidade 0,607 no conjunto de teste, superando o baseline RVD-R (AUC 0,678, F1 0,500).

O quinto objetivo — análise de importância e interpretabilidade — produziu o ranking de variáveis com importância intrínseca e com TreeSHAP, e a função `prever_com_explicacao` integra a previsão e a respetiva explicação SHAP num único output, encapsulada num endpoint REST.

O sexto objetivo — identificação de limitações éticas e metodológicas — é tratado de forma transversal nos Capítulos 6.4 e 7.5, com destaque para a natureza sintética dos dados, a inflação métrica por fuga de informação entre episódios e o enquadramento à luz do Regulamento de IA da UE e do RGPD.

7.3. Limitações

As limitações do trabalho podem ser agrupadas em três níveis. Ao nível dos dados, a utilização de um conjunto sintético, ainda que calibrado, impõe um teto à validade externa das conclusões e obriga a leituras prudentes do desempenho reportado. Ao nível do âmbito, o presente trabalho cobre a componente analítica e de modelação, ficando o desenho do sistema operacional (interface, integração com sistemas das forças de segurança, interoperabilidade) reservado para etapas posteriores. Ao nível da validação, a inexistência de dados reais e de utilizadores finais com quem testar o sistema impede uma avaliação plena dos requisitos de usabilidade e adequação operacional.

Outra limitação relevante prende-se com a definição dos limiares de decisão utilizados para converter a probabilidade estimada pelo modelo em níveis de risco operacionais. Neste trabalho, os limiares 0,33 e 0,66 foram usados como cortes exploratórios, adequados para demonstrar a lógica de funcionamento do protótipo, mas não validados para utilização real. A definição de thresholds robustos exigiria dados reais, análise de calibração probabilística e discussão com especialistas do domínio, uma vez que diferentes limiares podem alterar significativamente o equilíbrio entre falsos positivos e falsos negativos.

7.4. Trabalho Futuro

O trabalho futuro deverá desenvolver-se em várias linhas complementares, orientadas para a consolidação científica, técnica e operacional da solução proposta. A primeira e mais importante prende-se com a substituição progressiva dos dados sintéticos por dados reais, mediante o estabelecimento de protocolos institucionais com entidades competentes, nomeadamente a Guarda Nacional Republicana, a Polícia de Segurança Pública e a Comissão Nacional de Proteção de Dados. Esta etapa será essencial para validar a transferibilidade dos resultados obtidos, confirmar se os padrões identificados nos dados sintéticos se mantêm em contexto real e avaliar a robustez dos modelos perante a complexidade, incompletude e variabilidade dos dados efetivamente recolhidos no terreno.

Uma segunda linha de continuação consiste no aprofundamento da avaliação experimental dos modelos. Para além dos classificadores analisados neste trabalho, poderão ser exploradas outras abordagens adequadas a dados tabulares, incluindo modelos lineares regularizados, redes neuronais para dados estruturados, métodos de ensemble adicionais e arquiteturas explicáveis

por construção. Esta comparação deverá ser acompanhada por estudos de ablação, de modo a compreender o contributo individual dos diferentes grupos de variáveis, nomeadamente os itens da ficha RVD-R, os níveis de risco técnicos e as variáveis agregadas criadas durante o processo de feature engineering.

Deverá também ser realizada uma análise mais aprofundada dos limiares de decisão dos modelos. Neste trabalho, os limiares utilizados para converter a probabilidade estimada em níveis de risco foram assumidos como exploratórios, servindo apenas para demonstrar a lógica de funcionamento do protótipo. Em fases futuras, será necessário recorrer a técnicas formais de calibração probabilística, como curvas de calibração, Brier Score, Platt Scaling ou Isotonic Regression, bem como definir thresholds orientados por objetivos operacionais concretos, nomeadamente níveis mínimos de sensibilidade ou análises do custo relativo entre falsos positivos e falsos negativos. Esta etapa será determinante para transformar a classificação exploratória apresentada numa proposta mais robusta de apoio à decisão.

Outra linha relevante passa pela análise aprofundada da equidade e da estabilidade do desempenho entre subgrupos. Embora este trabalho tenha considerado a decomposição por tipologia de violência, a validação futura deverá alargar essa análise a outras dimensões relevantes, como sexo e idade da vítima e do agressor, relação entre vítima e agressor, presença de menores, tipo de vulnerabilidade, existência de informação em falta e eventual distribuição territorial dos casos. Esta avaliação será indispensável para identificar possíveis enviesamentos e garantir que o sistema não produz recomendações sistematicamente menos fiáveis para determinados grupos.

Por fim, deverá ser desenvolvida uma camada aplicacional mais completa, integrando a componente analítica num sistema de apoio à decisão com interface de utilizador, mecanismos de auditoria humana, registo das previsões realizadas e explicações acessíveis aos profissionais. O presente trabalho deixa preparada uma base técnica para essa evolução, através de um protótipo mínimo de serviço HTTP que expõe o modelo treinado, valida a estrutura e a coerência dos pedidos e devolve a explicação SHAP associada a cada previsão. No entanto, a sua integração numa solução operacional exigirá validação institucional, testes com utilizadores reais, definição de políticas de acesso, mecanismos de supervisão humana e garantias acrescidas de transparência, segurança e conformidade regulamentar.

7.5. Considerações sobre Inteligência Artificial

A integração de um sistema de Machine Learning em contexto de apoio à decisão policial e judicial exige um exame explícito da conformidade com o enquadramento regulamentar europeu e com os princípios éticos aplicáveis. Qualquer modelo é uma função do conjunto de treino e pode reproduzir ou amplificar enviesamentos nele presentes — risco particularmente relevante

quando se trata de apoiar decisões com efeito real sobre vidas humanas. A opacidade dos modelos ensemble dificulta a auditoria das suas recomendações, o que é incompatível com os princípios de transparência exigidos a um sistema de apoio à decisão policial e judicial. O presente trabalho posiciona-se de forma deliberada como sistema de apoio, e não de substituição, do juízo profissional, enquadramento que merece justificação detalhada à luz das normas em vigor.

Do ponto de vista regulamentar, o Regulamento de Inteligência Artificial da União Europeia, em vigor desde agosto de 2024, define o perímetro de aceitabilidade dos sistemas de IA em aplicação da lei [38]. O Artigo 5(1)(d) proíbe sistemas de avaliação autónoma de risco criminal baseados apenas em perfilagem, mas permite explicitamente sistemas que apoiem a avaliação humana com base em factos objetivos. O projeto enquadra-se nesta segunda categoria: as variáveis introduzidas no modelo são respostas estruturadas da ficha RVD-R, registadas pelos órgãos de polícia criminal a partir de factos verificáveis (denúncias, incidentes documentados, antecedentes registados), e a saída do modelo é uma probabilidade que informa, sem substituir, a decisão final do agente. O Anexo III(6) do mesmo Regulamento classifica os sistemas de IA em aplicação da lei como de alto risco, exigindo gestão de risco documentada, dados de treino de qualidade, supervisão humana incorporada, transparência sobre o funcionamento e registo de atividade. A arquitetura proposta atende a estes requisitos: a geração dos dados é integralmente documentada, o pipeline é reproduzível, a saída inclui contribuições por variável calculadas com TreeSHAP, e a decisão final permanece humana.

Em paralelo, o Regulamento Geral sobre a Proteção de Dados regula o tratamento das categorias especiais de dados pessoais relevantes para este domínio. O Artigo 9 abrange a informação relacionada com saúde, vida sexual e dados sensíveis associados a vítimas e agressores, exigindo base legal específica; o Artigo 22 limita as decisões automatizadas, incluindo perfilagem, com efeitos jurídicos ou significativos sobre a pessoa [40]. A articulação entre o Regulamento de IA e o RGPD está clarificada pelo Comité Europeu para a Proteção de Dados [41].

Em matéria de princípios éticos, o presente trabalho adere às Orientações para uma IA Fidedigna do Grupo de Peritos de Alto Nível da Comissão Europeia, em particular aos requisitos de agência humana, robustez técnica, transparência, equidade e responsabilização [39]. A interpretabilidade é tratada como requisito de desenho e não como acessório posterior, em linha com o argumento de Rudin de que, em decisões de alto risco, modelos transparentes por construção são preferíveis a explicações pós-hoc sobre modelos opacos [47]. Em consequência, a seleção do modelo a integrar na camada de serviço operacional não foi guiada apenas pelo desempenho preditivo medido no conjunto de teste: a estabilidade das estimativas de importância de variáveis e a concordância entre a importância intrínseca e os valores SHAP foram tomadas como critérios de igual peso, concretizando o argumento de Rudin no contexto operacional do RVD-R.

Em resposta a estes riscos, o trabalho adota três princípios operacionais. O primeiro é o de complementaridade: o modelo é desenhado para informar e não para substituir o juízo profissional, ficando o agente da polícia ou o magistrado como responsáveis pela decisão final, em conformidade com o Art. 5(1)(d) do Regulamento de IA [38]. O segundo é o de explicabilidade: a importância das variáveis é estimada e os modelos são passíveis de auditoria através de técnicas de Explainable AI, ainda que Rudin alerte para os limites destas técnicas em decisões de alto risco [47]. O terceiro é o de transparência metodológica: a totalidade do gerador, do pipeline e dos parâmetros é documentada e reproduzível.

A geração assistida por LLM, sobre a qual assenta todo o conjunto de modelação, acrescenta considerações próprias. O modelo de linguagem pode introduzir ou perpetuar enviesamentos dos seus dados de treino quando propõe distribuições ou correlações, e pode gerar plausibilidade aparente sem base empírica real. Estes riscos são atenuados pela ancoragem de cada parâmetro a uma fonte verificável, pela revisão humana de todas as sugestões e pela documentação dos prompts e ciclos de iteração, em linha com as boas práticas para dados sintéticos em domínios sensíveis [15].

Reconhece-se, contudo, que a aderência total a estes princípios só pode ser plenamente avaliada quando o sistema for testado sobre dados reais e auditado em contexto operacional, etapas que ficam reservadas para o trabalho futuro.

7.6. Apreciação Final

A realização deste projeto representou uma oportunidade particularmente significativa de aplicar conhecimentos adquiridos ao longo da Licenciatura em Engenharia Informática a um problema real, complexo e com elevado impacto social. A violência doméstica constitui um fenómeno sensível, multidimensional e profundamente marcado por fatores humanos, sociais, jurídicos e institucionais, pelo que o desenvolvimento de uma solução baseada em Inteligência Artificial exigiu uma abordagem cuidada, crítica e responsável.

Ao longo do trabalho, tornou-se evidente que a componente técnica, embora fundamental, não pode ser analisada de forma isolada. A construção de modelos preditivos para apoiar a previsão de reincidência obrigou não apenas à aplicação de técnicas de ciência de dados, pré-processamento, modelação e avaliação, mas também à compreensão das limitações éticas e metodológicas associadas ao domínio. Neste sentido, o projeto permitiu consolidar competências técnicas em Machine Learning, tratamento de dados, avaliação de modelos e interpretabilidade, mas também reforçou a importância da responsabilidade no desenho de sistemas que possam influenciar decisões humanas em contextos de elevada sensibilidade.

Um dos principais desafios encontrados foi a impossibilidade de acesso a dados reais durante o período de desenvolvimento. Esta limitação obrigou à construção de um conjunto de dados

sintéticos calibrado com base em estatísticas oficiais e literatura existente, permitindo testar a viabilidade metodológica do pipeline proposto. Apesar de esta opção não permitir validar conclusões definitivas sobre o comportamento dos modelos em contexto real, revelou-se essencial para estruturar uma solução tecnicamente coerente, reproduzível e preparada para futura validação com dados reais.

Outro aspeto particularmente relevante foi a necessidade de equilibrar desempenho preditivo e interpretabilidade. Num domínio como a violência doméstica, não basta que um modelo produza uma previsão; é necessário que essa previsão seja compreensível, auditável e enquadrada como apoio à decisão profissional. A utilização de técnicas de Explainable AI, nomeadamente através de valores SHAP, permitiu tornar mais transparente o contributo das variáveis para cada previsão, reforçando a ideia de que a Inteligência Artificial deve funcionar como uma ferramenta complementar ao juízo humano e nunca como substituto da avaliação profissional.

Considero que este projeto contribuiu de forma positiva para demonstrar o potencial da aplicação de modelos de Machine Learning à análise de risco em violência doméstica, ainda que de forma exploratória e limitada pela natureza sintética dos dados. Os resultados obtidos mostram que existe um sinal preditivo explorável e que é possível construir uma solução que combine modelação, avaliação, interpretabilidade e preocupação ética. No entanto, reforçam também a necessidade de validação futura com dados reais, avaliação por especialistas do domínio e análise mais aprofundada de questões como viés, equidade e calibração das previsões.

Em termos pessoais e académicos, este trabalho permitiu-me compreender melhor a importância da Engenharia Informática enquanto área capaz de produzir soluções com impacto para além do contexto estritamente tecnológico. Mais do que desenvolver modelos ou obter métricas de desempenho, este projeto demonstrou a importância de criar sistemas responsáveis, transparentes e socialmente conscientes. Assim, termino este percurso com a convicção de que a tecnologia pode desempenhar um papel relevante no apoio à decisão em contextos críticos, desde que seja desenvolvida com rigor científico, prudência ética e permanente supervisão humana.

Referências

- [1] Sistema de Segurança Interna, *Relatório Anual de Segurança Interna 2025*. Lisboa, Portugal: Secretaria-Geral do Sistema de Segurança Interna, 2026.
- [2] APAV, "Estatísticas APAV — Totais Nacionais 2024," Associação Portuguesa de Apoio à Vítima, Lisboa, 2025. [Online]. Disponível: <https://apav.pt/estatisticas-apav-totais-nacionais-2024/>. Acedido em: 18 de maio de 2026.
- [3] Comissão para a Cidadania e a Igualdade de Género, "Dados oficiais relativos à violência doméstica em Portugal — 4.º trimestre de 2024," CIG, Lisboa, 2025. [Online]. Disponível: <https://www.cig.gov.pt/2025/02/dados-oficiais-relativos-a-violencia-domestica-em-portugal-4o-trimestre-de-2024/>. Acedido em: 18 de maio de 2026.
- [4] D. Cerejo, "Nas teias da violência conjugal: uma análise dos participantes do Programa para Agressores de Violência Doméstica," Projeto pós-doutoral, FCSH, Universidade NOVA de Lisboa, 2020.
- [5] R. K. Hanson, L. Helmus e G. Bourgon, "The validity of risk assessments for intimate partner violence: A meta-analysis," *Public Safety Canada Research Report*, n.º 2007-07, 2007.
- [6] Portaria n.º 228/2025/1, de 21 de maio — Aprova o Instrumento de Avaliação de Risco em Violência Doméstica Revisto (RVD-R). *Diário da República*, 1.ª série, n.º 98, 21 de maio de 2025.
- [7] I. Almeida et al., "Instrumento de Avaliação de Risco em Violência Doméstica Revisto (RVD-R): Fundamentação científica e desenvolvimento," Egas Moniz School of Health & Science, Almada, 2025.
- [8] Universidade do Porto — Faculdade de Direito, "Estudo inédito sobre homicídio conjugal em Portugal," Escola de Criminologia, Porto, 2015. [Online]. Disponível: <https://noticias.up.pt/2015/07/20/faculdade-de-direito-lanca-estudo-inedito-sobre-homicidio-conjugal/>. Acedido em: 18 de maio de 2026.
- [9] D. Morais-Gonçalves, S. Lopes-Borges e H. Gaspar, "Reincidência, Fatores de Risco e Avaliação de Risco em Vítimas de Violência Doméstica," *Trabajo Social Global — Global Social Work*, vol. 8, n.º 14, pp. 3–28, 2018.
- [10] R. Berk e S. B. Sorenson, "Forecasting Domestic Violence: A Machine Learning Approach to Help Inform Arraignment Decisions," *Journal of Empirical Legal Studies*, vol. 13, n.º 1, pp. 94–115, mar. 2016. doi: 10.1111/jels.12098.
- [11] V. Hui, R. E. Constantino e Y. J. Lee, "Harnessing Machine Learning in Tackling Domestic Violence — An Integrative Review," *International Journal of Environmental Research and Public Health*, vol. 20, n.º 6, art. 4984, 2023. doi: 10.3390/ijerph20064984.

- [12] V. Borisov, K. Seßler, T. Leemann, M. Pawelczyk e G. Kasneci, "Language Models are Realistic Tabular Data Generators," in *International Conference on Learning Representations (ICLR)*, 2023. arXiv:2210.06280.
- [13] S. Hegselmann, A. Buendia, H. Lang, M. Agrawal, X. Jiang e D. Sontag, "TabLLM: Few-shot Classification of Tabular Data with Large Language Models," in *Proc. 26th Int. Conf. on Artificial Intelligence and Statistics (AISTATS)*, *PMLR*, vol. 206, pp. 5549–5581, 2023.
- [14] R. Shi, Y. Wang, M. Du, X. Shen, Y. Chang e X. Wang, "A Comprehensive Survey of Synthetic Tabular Data Generation," arXiv preprint arXiv:2504.16506, 2025.
- [15] D. Smolyak, M. V. Bjarnadóttir, K. Crowley e R. Agarwal, "Large language models and synthetic health data: progress and prospects," *JAMIA Open*, vol. 7, n.º 4, ooae114, dez. 2024. doi: 10.1093/jamiaopen/ooae114.
- [16] M. Liem, "SENSYN: Synthetic dataset protects privacy in criminological research," Universidade de Leiden, dez. 2024. [Online]. Disponível: <https://www.universiteitleiden.nl/en/news/2024/12/synthetic-dataset-protects-privacy-in-criminological-research>. Acedido em: 18 de maio de 2026.
- [17] T. Chen e C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, pp. 785–794, 2016. doi: 10.1145/2939672.2939785.
- [18] T. Akiba, S. Sano, T. Yanase, T. Ohta e M. Koyama, "Optuna: A Next-generation Hyperparameter Optimization Framework," in *Proc. 25th ACM SIGKDD Int. Conf. on Knowledge Discovery & Data Mining*, pp. 2623–2631, 2019. doi: 10.1145/3292500.3330701.
- [19] S. M. Lundberg e S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. arXiv:1705.07874.
- [20] S. M. Lundberg et al., "From local explanations to global understanding with explainable AI for trees," *Nature Machine Intelligence*, vol. 2, n.º 1, pp. 56–67, 2020. doi: 10.1038/s42256-019-0138-9.
- [21] Ministério Público, "Homicídios em contexto de violência doméstica 2023 — Análise de indicadores," Procuradoria-Geral da República, Lisboa, 2024. [Online]. Disponível: <https://www.ministeriopublico.pt/destaque/homicidios-em-contexto-de-violencia-domestica-2023-analise-de-indicadores>. Acedido em: 15 de maio de 2026.
- [22] H. Pinto et al., "IA para Previsão de Reincidência na Violência Doméstica em Portugal — Proposta de projeto," Candidatura Science4Policy 2025, CITECA, ISTECPorto, 2025.

- [23] Resolução do Conselho de Ministros n.º 61/2018, de 21 de maio — Estratégia Nacional para a Igualdade e a Não Discriminação 2018-2030 "Portugal + Igual." *Diário da República*, 1.ª série, n.º 97, 21 de maio de 2018.
- [24] Sistema de Segurança Interna, *Relatório Anual de Segurança Interna 2023*. Lisboa, Portugal: Secretaria-Geral do Sistema de Segurança Interna, 2024.
- [25] União de Mulheres Alternativa e Resposta, "Observatório de Mulheres Assassinadas — Relatório Anual 2024," UMAR, Lisboa, 2025. [Online]. Disponível: <http://www.umarfeminismos.org/index.php/observatorio-de-mulheres-assassinadas>. Acedido em: 15 de maio de 2026.
- [26] U. Grigaite et al., "Mental health conditions and utilisation of mental health services by survivors of physical intimate partner violence in Portugal: Results from the WHO world mental health survey," *Psychiatry Research*, vol. 334, art. 115801, 2024. doi: 10.1016/j.psychres.2024.115801.
- [27] E. C. V. Costa, J. Simões, P. Correia, T. McIntyre e M. G. Pereira, "The impact of interpersonal traumas in Portuguese women's psychological wellbeing: predictors of depression and post traumatic stress symptoms," *Journal of Sexual Aggression*, vol. 31, n.º 1, pp. 85–100, 2025. doi: 10.1080/13552600.2023.2300478.
- [28] M. Lisboa, Z. Barroso, J. Patrício e A. Leandro, *Violência e Género — Inquérito Nacional sobre a Violência Exercida contra Mulheres e Homens*. Lisboa, Portugal: Comissão para a Cidadania e Igualdade de Género, 2009.
- [29] C. Manita, C. Ribeiro e C. Peixoto, *Violência Doméstica: Compreender para Intervir — Guia de Boas Práticas para Profissionais das Forças de Segurança*. Lisboa, Portugal: Comissão para a Cidadania e Igualdade de Género, 2009.
- [30] S. Neves, E. Pio da Silva, J. Topa, J. Borges, A. Pereira e E. Silva, "Death Threats and Attempted Femicide in the Context of Domestic Violence in Portugal," *Social Sciences*, vol. 11, n.º 8, art. 347, 2022. doi: 10.3390/socsci11080347.
- [31] P. R. Kropp e S. D. Hart, "The Spousal Assault Risk Assessment (SARA) Guide: Reliability and validity in adult male offenders," *Law and Human Behavior*, vol. 24, n.º 1, pp. 101–118, 2000. doi: 10.1023/A:1005430904495.
- [32] N. Z. Hilton, G. T. Harris, M. E. Rice, C. Lang, C. A. Cormier e K. J. Lines, "A Brief Actuarial Assessment for the Prediction of Wife Assault Recidivism: The Ontario Domestic Assault Risk Assessment," *Psychological Assessment*, vol. 16, n.º 3, pp. 267–275, 2004. doi: 10.1037/1040-3590.16.3.267.

- [33] D. R. R. Cunha, M. E. Leitão e A. I. Sani, "Domestic Violence Victimization Risk Assessment in Children and Adolescents: A Systematic Review," **Social Sciences**, vol. 13, n.º 5, art. 259, 2024. doi: 10.3390/socsci13050259.
- [34] T. McDonagh, Á. Travers, C. Armour, T. Cunningham e M. Hansen, "Psychological Predictors of Recidivism for Intimate Partner Violence Perpetrators: A Systematic Scoping Review," **Trauma, Violence, & Abuse**, 2024. doi: 10.1177/15248380241284793.
- [35] R. Pires de Sousa et al., "Prosecutorial decision-making regarding offenders' social reintegration programs in intimate partner violence cases: A Portuguese study," 2022. [Online]. Disponível: <https://pmc.ncbi.nlm.nih.gov/articles/PMC9202915/>. Acedido em: 15 de maio de 2026.
- [36] J. Grogger, "Harnessing AI's predictive power to reduce domestic violence recidivism," 2025.
- [37] E. Turner, "Predicting domestic abuse (fairly) and police risk assessment," **CrimRxiv**, 2021.
- [38] Regulamento (UE) 2024/1689 do Parlamento Europeu e do Conselho, de 13 de junho de 2024, que estabelece regras harmonizadas em matéria de inteligência artificial (Regulamento Inteligência Artificial). **Jornal Oficial da União Europeia**, L 168, 12 de julho de 2024, pp. 1–144.
- [39] High-Level Expert Group on Artificial Intelligence, "Ethics Guidelines for Trustworthy AI," European Commission, Bruxelas, 8 de abril de 2019. [Online]. Disponível: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>. Acedido em: 15 de maio de 2026.
- [40] Regulamento (UE) 2016/679 do Parlamento Europeu e do Conselho, de 27 de abril de 2016, relativo à proteção das pessoas singulares no que diz respeito ao tratamento de dados pessoais (Regulamento Geral sobre a Proteção de Dados). **Jornal Oficial da União Europeia**, L 119, 4 de maio de 2016, pp. 1–88.
- [41] European Data Protection Board, "Opinion 28/2024 on certain data protection aspects related to the processing of personal data in the context of AI models," EDPB, Bruxelas, dezembro de 2024. [Online]. Disponível: <https://www.edpb.europa.eu/>. Acedido em: 15 de maio de 2026.
- [42] M. Veale e F. Zuiderveen Borgesius, "Demystifying the Draft EU Artificial Intelligence Act — Analysing the good, the bad, and the unclear elements of the proposed approach," **Computer Law Review International**, vol. 22, n.º 4, pp. 97–112, 2021. doi: 10.9785/crl-2021-220402.
- [43] L. Breiman, "Random Forests," **Machine Learning**, vol. 45, n.º 1, pp. 5–32, 2001. doi: 10.1023/A:1010933404324.
- [44] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," **Journal of Machine Learning Research**, vol. 12, pp. 2825–2830, 2011.

- [45] T. Fawcett, "An introduction to ROC analysis," **Pattern Recognition Letters**, vol. 27, n.º 8, pp. 861–874, 2006. doi: 10.1016/j.patrec.2005.10.010.
- [46] T. Saito e M. Rehmsmeier, "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets," **PLOS ONE**, vol. 10, n.º 3, art. e0118432, 2015. doi: 10.1371/journal.pone.0118432.
- [47] C. Rudin, "Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead," **Nature Machine Intelligence**, vol. 1, n.º 5, pp. 206–215, 2019. doi: 10.1038/s42256-019-0048-x.
- [48] República Portuguesa, "AI Portugal 2030 — Estratégia Nacional para a Inteligência Artificial," Agência para a Modernização Administrativa, Lisboa, 2019. [Online]. Disponível: <https://www.incode2030.gov.pt/ai-portugal-2030/>. Acedido em: 15 de maio de 2026.

Anexos

Anexo A: Cronograma

O desenvolvimento do projeto decorreu entre novembro de 2025 e maio de 2026, organizado nas cinco fases descritas no Capítulo 1, com sobreposição parcial entre fases adjacentes. O cronograma seguinte resume a sua distribuição ao longo do tempo.

Cronograma do projeto (novembro de 2025 a maio de 2026)

Fase	Nov	Dez	Jan	Fev	Mar	Abr	Mai
Fase 1 — Revisão de literatura e domínio							
Fase 2 — Geração e validação dos dados sintéticos							
Fase 3 — Análise exploratória e correlações							
Fase 4 — Pré-processamento e modelação							
Fase 5 — Redação do relatório e defesa							

Os meses de novembro e dezembro referem-se a 2025; os restantes a 2026. As células preenchidas indicam os meses em que cada fase esteve ativa.

Anexo B: Glossário Técnico-Clínico das variáveis RVD-R

Este anexo mapeia os identificadores técnicos utilizados no pipeline às formulações operacionais da ficha RVD-R, em Português. Cada secção da ficha é apresentada com os itens respetivos. As variáveis terminadas em `_bin` correspondem ao indicador binário de resposta afirmativa para a questão homónima. As últimas linhas reúnem as variáveis agregadas construídas no pipeline de pré-processamento.

Secção A: Fatores comuns (foco no agressor)

- A1** Antecedentes de queixas ou denúncias por violência doméstica, homicídio ou outros crimes.
- A2** Incumprimento, pelo agressor, de ordens do tribunal destinadas a proteger a vítima.

- A3** Consumo excessivo de álcool, drogas ou outras dependências por parte do agressor.
- A4** Instabilidade financeira ou laboral, incluindo desemprego recente.
- A5** Impulsividade, agressividade ou dificuldades de autocontrolo do agressor.
- A6** Tentativa ou ameaça de suicídio por parte do agressor.

7.6.1. Secção B: Severidade do incidente

- B1** Violência física recente exercida sobre a vítima.
- B2** Estrangulamento, sufocação ou afogamento.
- B3** Aumento da frequência ou da gravidade dos episódios no último mês.
- B4** Uso ou ameaça de uso de arma contra a vítima.
- B5** Ameaça ou tentativa de morte.
- B6** Violência sexual ou tentativa de o ser.
- B7** Conflitos familiares ou relacionais que potenciam a violência.
- B8** Relação de dependência entre vítima e agressor.
- B9** Isolamento da vítima das redes de apoio familiar e social.

7.6.2. Secção C1: Vulnerabilidade nas relações de intimidade

- C1.1** Perseguição ou comportamento de controlo sobre a vítima.
- C1.2** Ciúmes excessivos ou sentimentos de posse.
- C1.3** Separação recente ou intenção manifestada de separação.
- C1.4** Vítima em condição de particular vulnerabilidade.
- C1.5** Violência durante a gravidez ou no período pós-parto.

7.6.3. Secção C2: Vulnerabilidade contra crianças e jovens

- C2.1** Uso de violência pelo agressor para lidar com o comportamento da criança ou jovem.
- C2.2** Família com dificuldades de resposta às necessidades de desenvolvimento da vítima.
- C2.3** Vítima exposta a outros episódios de violência doméstica.

C2.4 Existência de processo de promoção e proteção sobre a vítima ou a família.

C2.5 Vítima em condição de particular vulnerabilidade.

7.6.4. Secção C3: Vulnerabilidade contra pessoas idosas

C3.1 Exigência de bens materiais à vítima por parte do agressor.

C3.2 Afastamento emocional do agressor em relação à vítima.

C3.3 Negligência das necessidades de cuidado da vítima.

C3.4 Vítima previamente exposta a violência doméstica perpetrada por outros agressores.

C3.5 Vítima em condição de particular vulnerabilidade.

7.6.5. Variáveis agregadas (engenharia de variáveis)

IDX_SEVERIDADE Índice de severidade física (soma de B2, B4, B5 e B6).

IDX_CONTROLO Índice de controlo e coação (soma de B3, B7, B8 e B9).

IDX_VULNERABILIDADE Índice de impulsividade do agressor (soma de A5 e A6).

IDX_AGRESSOR Índice de risco do agressor (soma de A2, A3 e A4).

RATIO_SIM Proporção de respostas afirmativas nas questões substantivas das secções A e B.

RISCO_ORD Codificação ordinal do nível de risco atribuído pela ficha (baixo=0, médio=1, elevado=2, extremo=3).

TIP_C1, TIP_C2, TIP_C3 Indicadores binários da tipologia de violência (intimidade, filio-parental, idosos).

7.7. Anexo C: Código-fonte e dados

Todo o código-fonte do projeto, bem como os ficheiros de dados sintéticos utilizados, está disponível em repositório Git. A estrutura do repositório organiza-se nos seguintes diretórios e ficheiros principais:

`dados/` — script gerador `gerar_rvd11_v3.py` e o ficheiro `rvd11_portugal_v3.csv` com as avaliações sintéticas geradas.

`Excluir_ultimo_episodio.ipynb` — notebook principal de modelação: divisão treino/teste por agressor, afinação com Optuna, treino dos três classificadores e avaliação no conjunto de teste.

`Previsao_reincidencia_com_SHAP.ipynb` — notebook dedicado à análise de interpretabilidade com TreeSHAP e à função `prever_com_explicacao`.

`api.py` — implementação do serviço HTTP com os endpoints `/saude` e `/prever`, autenticação por token e devolução da explicação SHAP na resposta.

`preprocess.py` — lógica de codificação das respostas RVD-R em variáveis para o modelo, partilhada entre o notebook e o serviço.

`validator.py` — cinco regras de coerência clínica aplicadas aos pedidos da API antes da inferência.

`relatorio/` — scripts e conteúdo do presente relatório, incluindo o notebook de produção de figuras `scripts/eda_metricas_relatorio.ipynb`, a bibliografia organizada em `bibliografia/referencias.md` e o gerador do documento Word `scripts/gerar_relatorio.py`.

O ficheiro `README.md` na raiz do repositório descreve os passos para reproduzir o ambiente, treinar o modelo, executar a API e correr os exemplos.